



دانشگاه صنعتی شریف

دانشکده مهندسی برق

پایان نامه کارشناسی

عنوان:

پردازش سیگنال‌های معزی صرعی با استفاده از ریزحالت‌ها

نگارش:

اردلان گرامی

استاد راهنما:

دکتر محمد باقر شمس‌الهی

استاد درس:

دکتر آشتیانی

تیر ۱۴۰۳

بِهِ نَامِ خَدَا

چکیده

از گذشته تا به امروز تحقیقات گسترهای برای مشاهده الگوهای رفتاری متفاوت سیگنال‌های مغزی افراد بیمار و سالم انجام شده است. همواره انتخاب روشی مناسب برای مشاهده الگوهای چالش برانگیز بوده و محققان به دنبال راهی مناسب برای بررسی الگوهای رفتاری سیگنال‌های مغزی (EEG) بوده‌اند. برای اولین بار در سال ۱۹۶۰ میلادی آقای Dietrich Lehmann و همکارانش مفهوم ریزحالات (microstates) را به عنوان بازه‌هایی پایدار از سیگنال مغزی معرفی نمودند. در این پژوهه سعی شده با استفاده از بیان خاصی از سیگنال‌های مغزی به نام ریزحالات به بررسی و مقایسه افراد سالم و بیمار بپردازیم. در تحقیقات اخیر ریزحالات‌ها کمک شایانی به مشاهده تفاوت الگوها در بیماری‌های مختلف مانند افسردگی، صرع، اسکیزوفرنی و ... کرده‌اند (مقاله [۱]).

در مسیر این پژوهه مشاهده می‌کنیم ریزحالات‌ها با نمایش الگوهای رفتاری متفاوت به خوبی به ما امکان طبقه‌بندی افراد سالم و بیمار را می‌دهند. همچنین با مقایسه میان ویژگی‌های ریزحالات‌ها و ویژگی‌های متداول دیگر برای طبقه‌بندی مشاهده خواهیم کرد طبقه‌بندی با ویژگی‌های ریزحالات‌ها دقیق و صحیح بالایی داشته و به ما امکان تفکیک الگوهای رفتاری سیگنال مغزی را می‌دهد.

- کلمات کلیدی :

صرع - سیگنال‌های مغزی صرعی - ریزحالات‌ها - طبقه‌بندی - توپوگرافی

Keywords :

Epilepsy - EEG - Microstates - Classification - Topography

فهرست مطالب

| | | |
|----|-------|---|
| ۱ | ۱ | مقدمه |
| ۱ | ۱.۱ | پیش درآمد |
| ۱ | ۲.۱ | چالش‌ها |
| ۲ | ۳.۱ | اهداف پژوهش |
| ۲ | ۴.۱ | ساختار گزارش |
| ۳ | ۲ | مفاهیم کلی |
| ۳ | ۱.۲ | مقدمه |
| ۳ | ۲.۲ | سیگنال‌های مغزی (EEG) |
| ۵ | ۳.۲ | پیش پردازش سیگنال‌های مغزی |
| ۷ | ۴.۲ | صرع |
| ۹ | ۵.۲ | ریزحالت‌ها |
| ۱۰ | ۶.۲ | طبقه بندی سیگنال‌های EEG صرعی |
| ۱۶ | ۷.۲ | مفاهیم یادگیری ماشین استفاده شده |
| ۲۲ | ۸.۲ | جمع بندی |
| ۲۳ | ۳ | مروجی بر ادبیات |
| ۲۳ | ۱.۳ | مقدمه |
| ۲۴ | ۲.۳ | مقالات‌های بررسی شده در پردازش سیگنال‌های مغزی صرعی با استفاده از ریزحالت‌ها |
| | ۱.۲.۳ | مقاله اول [۱] |
| ۲۴ | | Altered peri-seizure EEG microstate dynamics in patients with absence epilepsy |
| ۲۴ | ۲.۲.۳ | مقاله دوم [۲] |
| | | Intrinsic Brain Activity in Temporal Lobe Epilepsy With and Without Depression: Insights From EEG microstates |
| ۲۵ | | |

| | | |
|----|---|--------------|
| ۲۷ | مقاله سوم [۳] Machine learning detects EEG microstate alterations in patients living with temporal lobe epilepsy | ۳.۲.۳ |
| ۲۸ | مقاله چهارم [۴] EEG microstates analysis in patients with epilepsy | ۴.۲.۳ |
| ۲۹ | مقاله پنجم [۵] EEG-based classification of epilepsy and PNES: EEG microstate and functional brain network features | ۵.۲.۳ |
| ۳۰ | مقاله ششم [۶] EEG Microstate Features as an Automatic Recognition Model of High-Density Epileptic EEG Using Support Vector Machine | ۶.۲.۳ |
| ۳۱ | مقاله های بررسی شده در پردازش سیگنال های مغزی صرعی بدون ریز حالت ها [۷] Epileptic Seizures Prediction Using Machine Learning Methods | ۳.۳ |
| ۳۵ | مقاله دوم [۸] Spike-microstates correlate with interictal epileptogenic discharges: a marker for hidden epileptic activity | ۲.۳.۳ |
| ۳۷ | | |
| ۳۸ | جمع بندی | ۴.۳ |
| ۳۹ | | ۴ پیاده سازی |
| ۴۰ | مقدمه | ۱.۴ |
| ۴۱ | پایگاه داده | ۲.۴ |
| ۴۲ | روش | ۳.۴ |
| ۴۳ | پیش پردازش | ۱.۳.۴ |
| ۴۴ | محاسبه Global Field Power | ۲.۳.۴ |
| ۴۵ | خوشه بندی بهینه سیگنال (Clustering) | ۳.۳.۴ |
| ۴۶ | تطبیق خوشه ها بر روی (GFP) | ۴.۳.۴ |
| ۴۷ | طبقه بندی | ۵.۳.۴ |
| ۴۸ | معیار ارزیابی | ۴.۴ |
| ۴۹ | نتایج و توضیحات | ۵.۴ |
| ۵۰ | نمایش داده چند نمونه پس از پیش پردازش | ۱.۵.۴ |
| ۵۱ | نمایش GFP چند نمونه | ۲.۵.۴ |
| ۵۲ | تعداد خوشه بهینه برای نمونه ها در هر کلاس | ۳.۵.۴ |

| | | |
|--------------|---------------------------------|-------|
| ۴۸ | نمایش توپوگرافی | ۴.۵.۴ |
| ۵۳ | طبیق خوشها بر روی GFP | ۵.۵.۴ |
| ۵۶ | پارامترهای خروجی | ۶.۵.۴ |
| ۵۶ | طبقه بندی | ۷.۵.۴ |
| ۵۷ | نتیجه گیری | ۶.۴ |
| ۵۸ | نتیجه گیری و پیشنهادات | ۵ |
| ۵۸ | جمع بندی و نتیجه گیری | ۱.۵ |
| ۵۸ | پیشنهادات | ۲.۵ |
| ۵۹ | مراجع | ۶ |

سپاس

از استاد راهنمای بزرگوارم جناب دکتر شمس الهی بابت زحمات و آموزش‌های بی‌درباره ایشان در مسیر انجام پژوهه تقدیر و تشکر می‌کنم؛ امیدوارم با عملکرد خود توانسته باشم قدردان زحمات ایشان باشم. همچنین از دکتر آشتیانی بابت زحمات بی‌درباره ایشان تشکر می‌کنم و امیدوارم همیشه سلامت باشند.

فصل ۱

مقدمه

۱.۱ پیش درآمد

هم اکنون در دنیا شاهد گسترش بیماری‌هایی همچون صرع، اسکیزوفرنی، افسردگی و ... هستیم. میلیون‌ها نفر در جهان از بیماری‌های ذکر شده رنج می‌برند بدون آنکه درمان مشخصی وجود داشته باشد یا بتوان به گونه‌ای وضعیت آن‌ها را کنترل کرد که زندگی عادی خود را داشته باشند. در سال‌های گذشته شاهد افزایش چشمگیر مطالعات روی افراد مبتلا به بیماری‌های ذکر شده با استفاده از بررسی فعالیت مغزی آن‌ها بوده‌ایم. دلیل این امر ارتباط تنگاتنگ این بیماری‌ها با فعالیت مغز می‌باشد به گونه‌ای که مشاهده شده است در نواحی مرتبط با یک بیماری فعالیت آن ناحیه در افراد مبتلا و سالم بسیار متفاوت می‌باشد.

یک راه بررسی عملکرد مغز مشاهده و ارزیابی سیگنال‌های مغزی (EEG) می‌باشد. در بررسی سیگنال مغزی همواره در تحقیقات به دنبال استفاده از ابزاری مناسب برای بیان تفاوت‌ها و استخراج ویژگی برای طبقه بنده می‌باشند. این ابزار می‌تواند از مفاهیم مختلف سیگنال مغزی مانند قدرت، طیف، پایداری و ... سیگنال مورد نظر مشتق شده باشد. در این پژوهه ما بر روی مفهوم شبه پایداری سیگنال مغزی (EEG) که در بازه‌های زمانی محدود قابل مشاهده است متمرکز می‌شویم.

۲.۱ چالش‌ها

اولین چالش ما در تحلیل سیگنال‌های مغزی (EEG) پیش پردازش داده مورد استفاده می‌باشد. دلیل این چالش وجود نویزهای گوناگون و artefact می‌باشد. از آنجایی که دامنه سیگنال EEG بسیار کم بوده و نویزها می‌توانند کاملاً تحلیل ما را مختل کنند بهترین راه برای حذف نویزهای موجود استفاده از فیلترهای مناسب مانند فیلتر notch برای حذف نویز برق شهر، ICA برای نویزهای حرکتی (artefact) و فیلترهای میانگذر لازم می‌باشد.

چالش دیگر ما استخراج خود ریزحالات‌ها می‌باشد چرا که مسئله شبه پایداری در سیگنال‌های مغزی معیاری است که می‌تواند تنها با تغییری کوچک در الگوریتم استخراج توپوگرافی (بخش ۵.۲) تغییر کند و نتایج نهایی ما دست‌خوش تغییر شود (در ادامه مشاهده خواهیم کرد معیاری global برای توپوگرافی‌ها وجود دارد که بایستی به آن‌ها برسیم)؛ بنابراین انجام دقیق پایپلاین (شکل ۷-۲) بسیار مهم می‌باشد. چالش دیگری که آن را در بخش پیاده سازی نیز خواهیم دید استخراج ویژگی‌های ریزحالات‌ها از یک سیگنال مغزی می‌تواند

مبتنی بر کل بازه سیگنال حاصل از الکتروودها (GFP) باشد یا ویژگی‌ها را از روی بازه‌های غیر همپوشان ۱۱ ثانیه‌ای بدست آورد. در نهایت چالش اصلی ما طبقه بندی مناسب با استفاده از ویژگی‌های ریزحالت‌ها (بخش ۵.۲) می‌باشد که انجام درست مسیر رسیدن به ریزحالت‌ها برای رسیدن به طبقه بندی با دقت بالا ضروری می‌باشد.

۳.۱ اهداف پروژه

در چنین پروژه‌ای ما بایستی در هر مرحله به اهداف تعیین شده دست پیدا کنیم تا بتوانیم در با اطمینان مرحله بعد را پیاده سازی کنیم. اولین هدف پروژه پیدا کردن دیتاستی مناسب برای پیشبرد پروژه می‌باشد. هدف بعدی پیش‌پردازش مناسب می‌باشد که با آن در بخش چالش‌های آشنای گشته‌یم. در مرحله بعد بایستی بتوانیم ریزحالت‌ها را به درستی استخراج کنیم، یکی اهداف تعیین شد در اینجا بدست آوردن توپوگرافی خوش‌های ریزحالت‌ها مبتنی بر الگوریتم‌های پیاده سازی است که هدف اصلی رسیدن به معیار global معرفی شده در مقاله‌های مختلف (مانند مقاله [۶]) است. در مرحله بعد بایستی ویژگی‌ها یعنی ریزحالت‌ها را به درستی محاسبه کنیم. در انتهایا ما بایستی بر اساس ویژگی‌های ریزحالت‌ها و ویژگی‌های conventional طبقه بندی لازم را انجام بدھیم. هدف نهایی نیز مشاهده طبقه بندی با دقت بیشتر و بهتر (طبق مقاله‌های مطالعه شده) با استفاده از ویژگی‌های ریزحالت‌ها در مقایسه با دیگر ویژگی‌ها است.

۴.۱ ساختار گزارش

تا به اینجا به طور بسیار کوتاه با آنچه در پروژه قرار است انجام شود آشنا شدیم، اکنون به بیان روند کلی کار و گزارش در ادامه می‌پردازیم.

در فصل دوم ابتدا مقدمه‌ای راجع به روند کلی پروژه بیان کرده و سپس اجزای این روند را به طور جداگانه به تفصیل توضیح می‌دهیم. در فصل دوم گزارش با جمع بندی از آنچه بیان شد ادامه می‌یابد. در فصل سوم به بررسی مقالات خوانده شده و بیان خلاصه‌ای از هر یک خواهیم پرداخت. در فصل چهارم یک مقاله منتخب را پیاده سازی خواهیم کرد و نتایج آن را مورد بررسی قرار خواهیم داد و در نهایت در فصل پنجم از آنچه خوانده شده و کارهای انجام شده تا کنون جمع بندی و نتیجه گیری خواهیم داشت.

فصل ۲

مفاهیم کلی

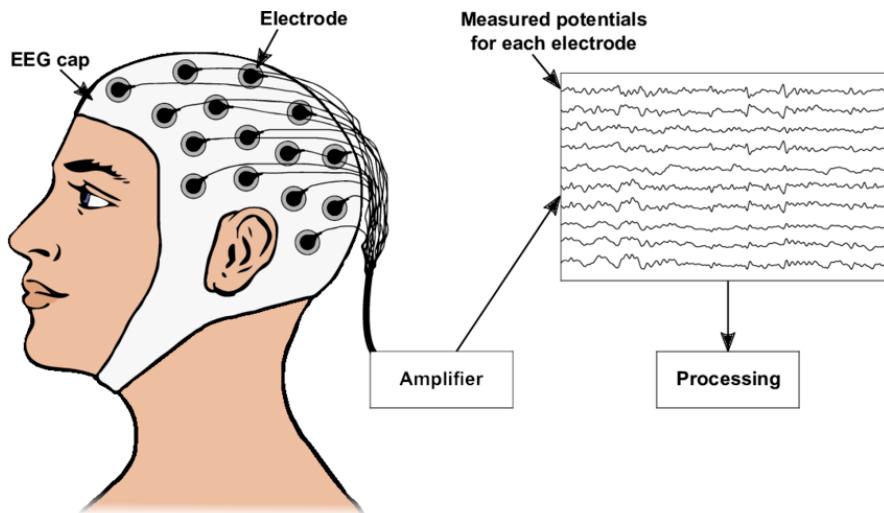
۱.۲ مقدمه

در فصل اول صحبت از طبقه بندی شد و این سوال پیش می‌آید که ما چگونه می‌توانیم به یک طبقه بندی مناسب برای سیگنال‌های مغزی بیماران صریع دست یابیم؟ در واقع ابتدا با استی ریزحالت‌ها را از سیگنال مغزی استخراج کنیم که این امر مستلزم پیش پردازش سیگنال‌های مغزی است. بعد از انجام پیش پردازش سیگنال‌های مغزی باید ریزحالت‌ها را استخراج کرده و دسته بندی کنیم. بنابراین در این فصل سعی بر توضیح مفاهیم استفاده شده در رسیدن به هدف اصلی پروژه یعنی طبقه بندی سیگنال‌های مغزی است.

۲.۲ سیگنال‌های مغزی (EEG)

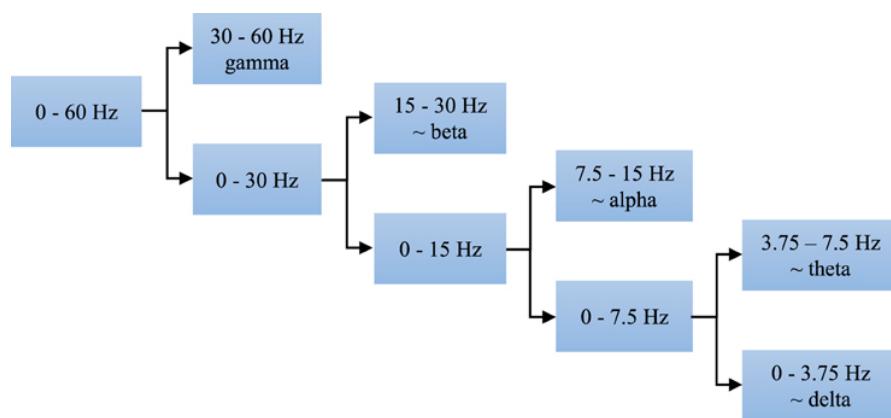
الکتروانسفالوگرام یا همان EEG یک تست برای مشاهده فعالیت الکتریکی مغز است و این سیگنال‌ها از طریق الکترودهایی که بر روی پوست سر قرار دارد بدست می‌آیند (شکل ۱-۲). این روش اولین بار در سال ۱۹۲۹ استفاده شد. دلیل استفاده گسترده از این سیگنال این است که به ما قابلیت تشخیص بیماری‌های مغزی و ... را می‌دهد و همچنین از دیگر ویژگی‌های منحصر به فرد این تست ثبت فعالیت مغز حتی در حالت خواب است.

در بسیاری از بیماری‌ها با مانیتور کردن سیگنال مغزی EEG می‌توانیم اثرات آن را بر روی فعالیت الکتریکی مغز مشاهده کنیم؛ مانند بیماری صرع که در ادامه به تفصیل آن را توضیح خواهیم داد.



شکل ۲-۱ دریافت سیگنال EEG از یک فرد مورد آزمایش [۱]

سیگنال مغزی EEG شامل باندهای مختلف فرکانسی در (شکل ۲-۲) است:



شکل ۲-۲ باندهای مختلف فرکانسی سیگنال EEG [۲]

در آزمایش‌های مختلف تعداد الکترودها برای ضبط سیگنال مغزی صرعي می‌تواند متفاوت باشد و به طور کلی از ۱۶ تا ۲۵۶ عدد در سیستم ۲۰-۱۰ متغیر است. در باندهای مختلف فرکانسی رفتار سیگنال متفاوت بوده و ویژگی‌های مختص خود را دارد. این امر در آینده برای بررسی سیگنال‌های مغزی صرعي مشهود خواهد بود.

۳۰.۲ پیش پردازش سیگنال‌های مغزی

پیش پردازش سیگنال‌های مغزی شامل چند بخش مختلف می‌تواند باشد و البته بسته به هدف هر تحقیق ممکن است برخی از جزئیات تغییر کند.

- حذف مصنوعات (artifacts):

به هنگام ضبط سیگنال EEG فرد بیمار یا سالم ممکن است تحرکاتی در قسمت‌های مختلف بدن خود داشته باشد که خارج از اهداف آزمایش است (مانند پلک زدن، تکان دادن دست و ...)، بنابراین بایستی اثرات مصنوعات را از بین ببریم. برای انجام این کار از روش‌های مختلفی مانند BSS، ICA و ... استفاده می‌شود.

- استفاده از یک فیلتر میانگذر:

برای حذف اثر نویز و artifacts در خارج از بازه مورد نظر ما از یک فیلتر میانگذر (معمولًاً از ۵۰ تا ۷۰ هرتز) استفاده می‌شود.

- کانال‌های خارج از هدف:

سیگنال‌های کانال‌هایی به شدت نویزی حذف می‌شوند.

- تنظیم کانال مرجع:

انتخاب کانال مرجع (بر اساس الکترودها) می‌تواند اثر زیادی بر روی مجموعه سیگنال‌های مغزی EEG بگذارد. یکی از روش‌ها averaging reference می‌باشد.

- بخش بندی:

برای بررسی بخش خاصی از سیگنال و جلوگیری از بیش‌برازش در آموزش داده‌ها می‌توان از تقسیم سیگنال به چند بازه زمانی (epochs) استفاده کرد.

- بازسازی بخش‌های نامناسب سیگنال:

اگر در یک epoch از سیگنال، سیگنال مغزی نامناسب ثبت شده بود با استفاده از روش درونیابی آن قسمت از سیگنال را بازیابی می‌کنیم که البته این درونیابی (interpolation) با استفاده از سیگنال‌های الکترودهای اطراف همان الکترود صورت می‌گیرد چرا که عملکرد مغز به صورت ناحیه‌ای است بدین معنی که سیگنال خراب شده یک ناحیه را با استفاده از الکترودهای همان ناحیه درونیابی می‌کنیم [۱۱]، [۳]، [۸].

- معرفی برخی فیلترها برای کاهش نویز:

الف) Averaging filter:

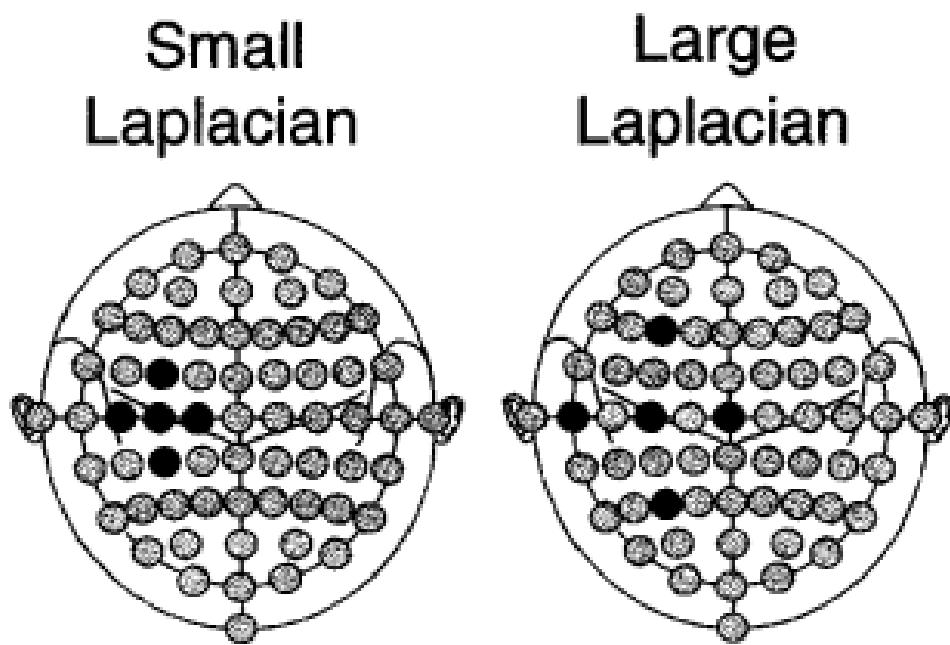
این فیلتر FIR اولین بار در سال ۱۹۷۰ توسط Chew et al معرفی شد. کار اصلی این فیلتر در حوزه پردازش سیگنال کاهش نویز تصادفی از بسته‌های (epochs) مورد نظر سیگنال است. عملیات انجام شده توسط این فیلتر مانند نام آن است؛ بدین معنی که با میانگین گیری از بسته‌های مختلف اثر نویز رندوم را از بین

می‌برد.

این فیلتر در بحث پردازش تصاویر پزشکی با میانگین گیری میان پیکسل‌های اطراف یک پیکسل کاهش نویز تصویر را انجام می‌دهد. همچنین میانگیری توسط این فیلتر با توجه به اطلاعات و وضعیت سیگنال می‌تواند به صورت وزن دار باشد.

ب) large & small laplacian filter

این فیلتر با توجه به موقعیت فضایی-مکانی الکترودهای مغزی با استفاده از مشتق دوم به کاهش نویز (افزایش SNR) می‌پردازد و همچنین اثرات artifacts را کاهش می‌دهد. در دو نوع small و large این فیلتر توجه به ترتیب بر الکترودهای نزدیک (همسایه) و الکترودهای دورتر است و در نوع اول به نوعی ما اثرات الکترودهای دورتر را کم می‌کنیم؛ این مفهوم در شکل ۳-۲ آمده است:



[۱۰] دو نوع فیلتر laplacian

از مزیت‌های این فیلتر می‌توان به موارد زیر اشاره کرد:

- * به ما تفکیک مغز و نورون‌های هر ناجیه با توجه به نحوه عملکردشان کمک می‌کند.
- * با کاهش نویز به ما دید واضحی از فعالیت نورون‌ها می‌دهد.
- * با برجسته کردن ویژگی‌های خاص و به حداقل رساندن تأثیر منابع دور، این فیلتر می‌تواند به محلی سازی منابع فعالیت عصبی در مغز کمک کند.

۴.۲ صرع

صرع یک نوع اختلال عصبی مزمن غیر واگیردار است که مشخصه آن تشنج بیمار می‌باشد. هم‌اکنون در جهان حدود ۵۰ میلیون انسان مبتلا به صرع می‌باشند و شاید باعث تعجب باشد که حدود ۸۰ درصد بیماران صرعی در کشورهایی با درآمد کم و متوسط زندگی می‌کنند. تشنج‌های صرعی می‌تواند شدت بسیار متغیری داشته باشد به گونه‌ای که ممکن است فرد حتی متوجه آن نشود و فقط اثر این تشنج بر روی سیگنال‌های مغزی قابل مشاهده باشد [۵].

البته حدود ۷۰ درصد از افراد مبتلا به صرع با استفاده از روش‌های مناسب می‌توانند بدون وقوع تشنج‌های صرعی به زندگی خود ادامه دهند و به طور کلی ۲۵ درصد از انواع صرع قابل پیشگیری می‌باشد که برای بررسی این موضوع بهتر است به دلایل مختلف ابتلا به صرع نگاهی بیندازیم:

- * آسیب مغزی ناشی از علل قبل از تولد (مانند از دست دادن اکسیژن یا ضربه در هنگام تولد، وزن کم هنگام تولد).

- * ناهنجاری‌های مادرزادی یا شرایط ژنتیکی همراه با ناهنجاری‌های مغزی مرتبط.

- * آسیب شدید سر؛

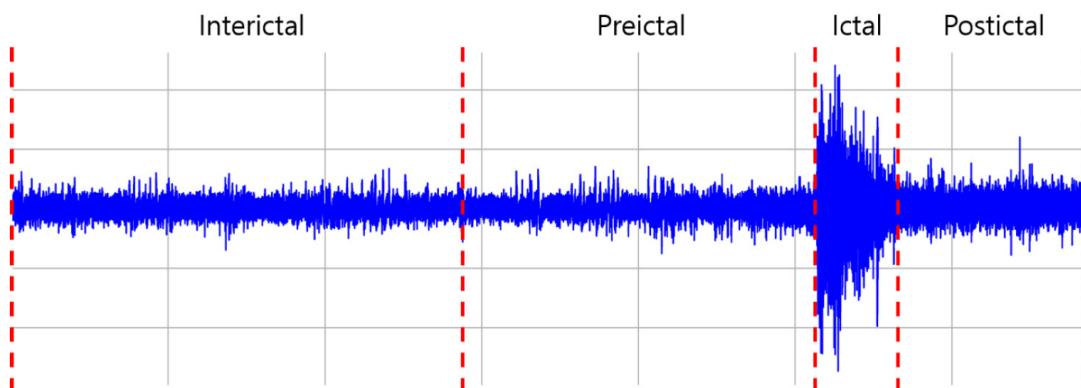
- * سکته مغزی که میزان اکسیژن را به مغز محدود می‌کند.

- * عفونت مغزی مانند منژیت، آنسفالیت یا نوروسیستیسرکوز،

- * سندروم‌های ژنتیکی خاص؛ و

- * تومور مغزی

برای تشخیص وقوع تشنج‌های صرعی بایستی به تغییرات سیگنال‌های مغزی به هنگام وقوع تشنج مراجعه کنیم. به طور کلی سیگنال‌های مغزی بیماران صرعی شامل ۴ فاز است:



شکل ۲-۴ فازهای مختلف سیگنال مغزی صرعی [۳]

الف) فاز ictal

با توجه به شکل قابل حدس می‌باشد که در این باز فرد دچار تشنج شده و سیگنال مغزی وی کاملاً تحت تاثیر است و دامنه ولتاژ افزایش یافته است.

بروز علائم فیزیکی در این فاز به اوج خود می‌رسد و بیمار صرعی بیشترین فشار را بر روی عضلات خود تجربه می‌کند. گریه کردن و پرش اندام از دیگر علائم فیزیکی این فاز است.

ب) فاز pre-ictal

این بازه مربوط به لحظات قبل از وقوع تشنج است و سیگنال مغزی بیمار صرعی در این بازه دچار تغییرات

شده و همچنین این تغییرات می‌تواند خود را به صورت فیزیکی در فرد مانند گریه کردن، تغییر در حالت عضلات و ... نشان بدهد. البته در اکثر موقع فرد متوجه تغییری نمی‌شود. از مشخصات این بازه برای انجام تحقیق در پیشینی صرع استفاده می‌شود و در یکی از مقالات که در ادامه بررسی می‌شود با دقت حدوداً ۸۲ درصدی موفق به پیشینی صرع ۱۸ دقیقه قبل از وقوع شده‌اند.

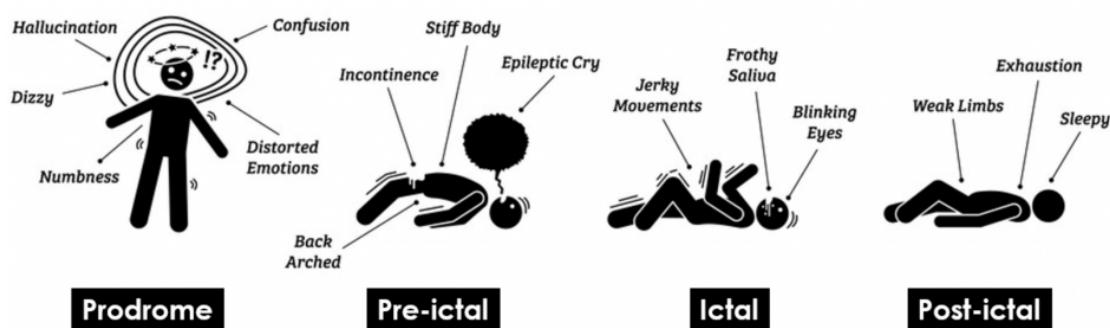
ج) فاز post-ictal

همانطور که مشخص است بعد از وقوع تشنج و فاز ictal وارد فاز بعدی یعنی post-ictal می‌شویم و دامنه ولتاژ سیگنال مغزی در این حالت نیز دست خوش تغییر نسبت به حالت عادی است و فرد در این فاز احساس خواب‌آوردنگی می‌کند و دچار سرگیجه می‌شود.

د) فاز interictal

در واقع بهترین توصیف برای این فاز از سیگنال مغزی بیماران صرعی معادل دانستن این فاز یا حالت عادی سیگنال مغزی یک فرد سالم است؛ اما در تحقیقات اخیر مشاهده شده که در سیگنال مغزی صرعی این فاز شامل پیک‌های ولتاژی در برخی لحظات است و این پیک‌ها را Interictal Epileptic Discharged یا به اختصار IED می‌گویند که در مقاله [۸] بیشتر به آن پرداخته‌ایم. با توجه به IED‌ها می‌توان با پردازش سیگنال در این فاز اطلاعات مفیدی بدست آورد.

- یک تقسیم بندی فازی از نظر بروز علائم فیزیکی در بیمار صرعی:

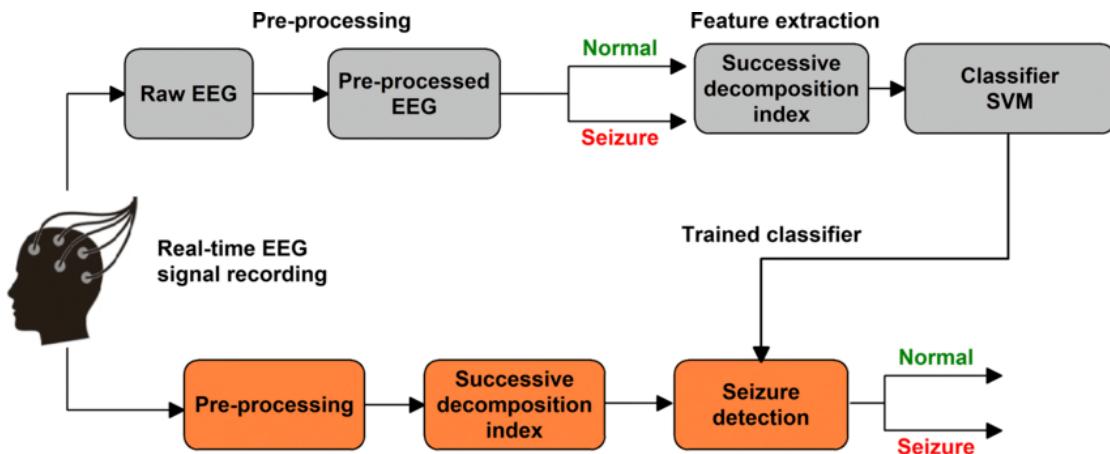


شکل ۲-۵ واکنش‌های فیزیکی بدن به هنگام تشنج صرعی [۲]

انواع مختلف صرع که در ادامه مورد بررسی قرار می‌گیرد [۱۳]:

- Absence seizures
- Temporal lobe epilepsy
- Generalized seizures
- Focal seizures
- Myoclonic
- Atonic
- Myoclonic epilepsy
- Atonic seizures
- Epilepsy syndromes

با توجه به علائم فیزیکی بیان شده ارائه روش هایی برای پیشگیری یا درمان صرع کاملاً ضروری است. یک پایپلین کلی بررسی صرع با استفاده از سیگنال مغزی (EEG):



شکل ۲-۶ پایپلین کلی بررسی صرع [۸]

۵.۲ ریزحالت‌ها

همانطور که بیان شد ما برای انجام تحقیقات دقیق به سراغ سیگنال‌های مغزی می‌رویم اما بررسی گسترده سیگنال مغزی بدون مشخص کردن یک ویژگی از آن برای تحقیق بیشتر خطای کار را بسیار زیاد می‌کند و اینجا است که ما به سراغ یک ویژگی از سیگنال‌های مغزی (EEG) می‌رویم. اما برای فهم بهتر اینکه ریزحالت چیست در ادامه به تفصیل آن را بررسی می‌کنیم.

مفهوم ریزحالت‌ها اولین بار توسط Dietrich Lehmann و همکارانش در تحقیقی در دانشگاه زوریخ سوئیس در میان سال‌های ۱۹۷۱ تا ۱۹۸۷ مطرح شد.

هنگامی که یک فعالیت توسط انسان صورت می‌گیرد یا تغییری در حالت فرد رخ می‌دهد، در سیگنال‌های مغزی (EEG) افزایش دامنه ولتاژ بوجود آمده و این افزایش ولتاژ به صورت یک ماقزیم محلی است که توپوگرافی مغز (brain topography) بازه‌ای چند میلی ثانیه‌ای قبل و بعد این ماقزیم محلی ثابت است. ریزحالت‌ها نیز مبتنی بر همین موضوع تعریف شده‌اند.

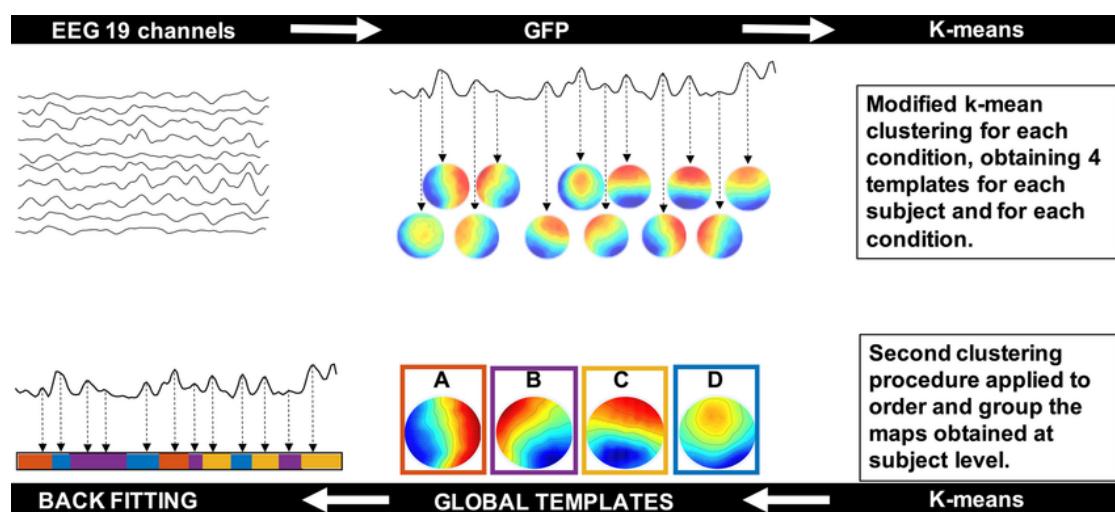
طبق این مفاهیم، ریزحالت یک ویژگی است سیگنال مغزی EEG است که شامل دوره‌های زمانی ۸۰ الی ۱۰۰ میلی ثانیه‌ای شبه پایدار (quasi-stable) است. برای استفاده از ریزحالت‌ها یک روش ایجاد از روی سیگنال‌های مغزی وجود دارد که در ادامه به بیان آن می‌پردازیم [۱۹].

پس از پیش پردازش سیگنال های مغزی EEG قصد داریم یک سیگنال برایند از تمامی کانال های موجود بدست آوریم. برای انجام این کار از فرمول GFP استفاده می کنیم:

$$GFP = \sqrt{\frac{\sum_{i=1}^K (V_i(t) - V_{mean}(t))^2}{K}} \quad (1,2)$$

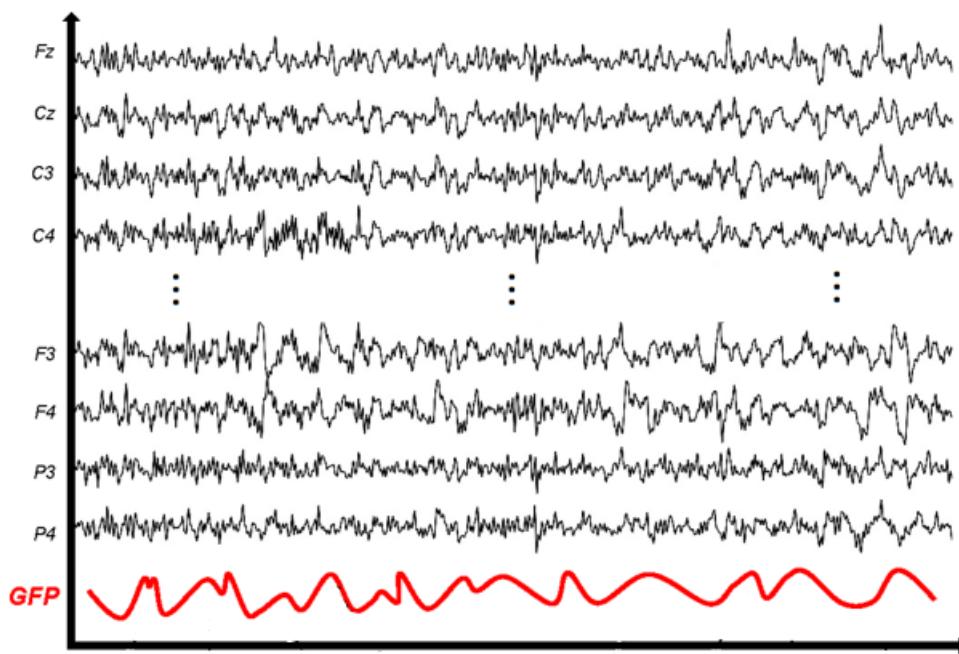
که K در آن تعداد الکتروودها، $(V_i(t)$ ولتاژ الکتروود i در لحظه t و $V_{mean}(t)$ میانگین ولتاژ الکتروودها در لحظه t می باشد.

در شکل ۷-۲ مسیر کلی بررسی ریزحالت ها را می توان مشاهده کرد. از این مسیر (pipeline) در ادامه برای طبقه بندی سیگنال های مغزی صرعی استفاده خواهیم کرد و پس انجام مرحله آخر پارامترهای مناسب را برای ریزحالت ها microstates تعریف می کنیم.



شکل ۷-۲ مسیر (pipeline) بررسی صرع با استفاده از ریزحالت ها [۱]

بنابراین ابتدا از سیگنال های تمامی کانال ها یک سیگنال میانگین به نام V_{mean} را محاسبه می کنیم و سپس با سنجیدن اختلاف سیگنال یک کانال با آن به نوعی انحراف معیار کانال ها را محاسبه می کنیم (فرمول ۱،۲)! پس از اعمال این فرمول ریاضی بر روی سیگنال ها ما یک سیگنال برایند داریم که با توجه به آن در زمان هایی که در سیگنال های اصلی پیک ولتاژ داریم، در سیگنال GFP نیز به صورت ماقزیم محلی نمایان می شوند:

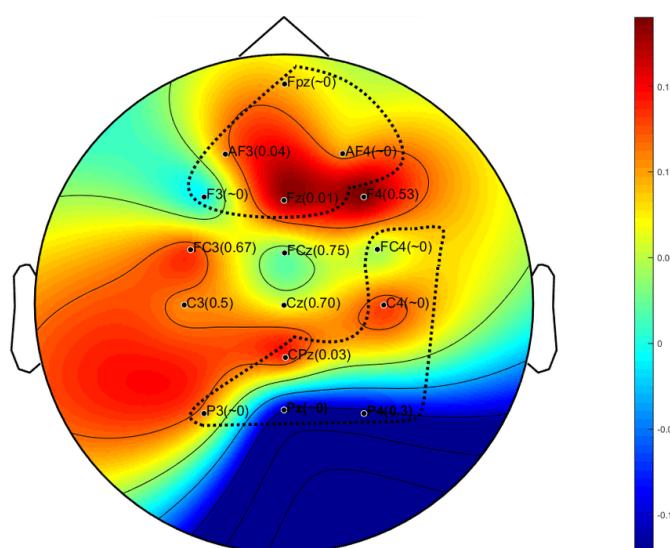


شکل ۲-۸ اعمال فرمول GFP [۹]

همانطور که در شکل ۲-۸ مشاهده می‌کنیم سیگنال حاصل شامل ماکریتم‌های محلی است.

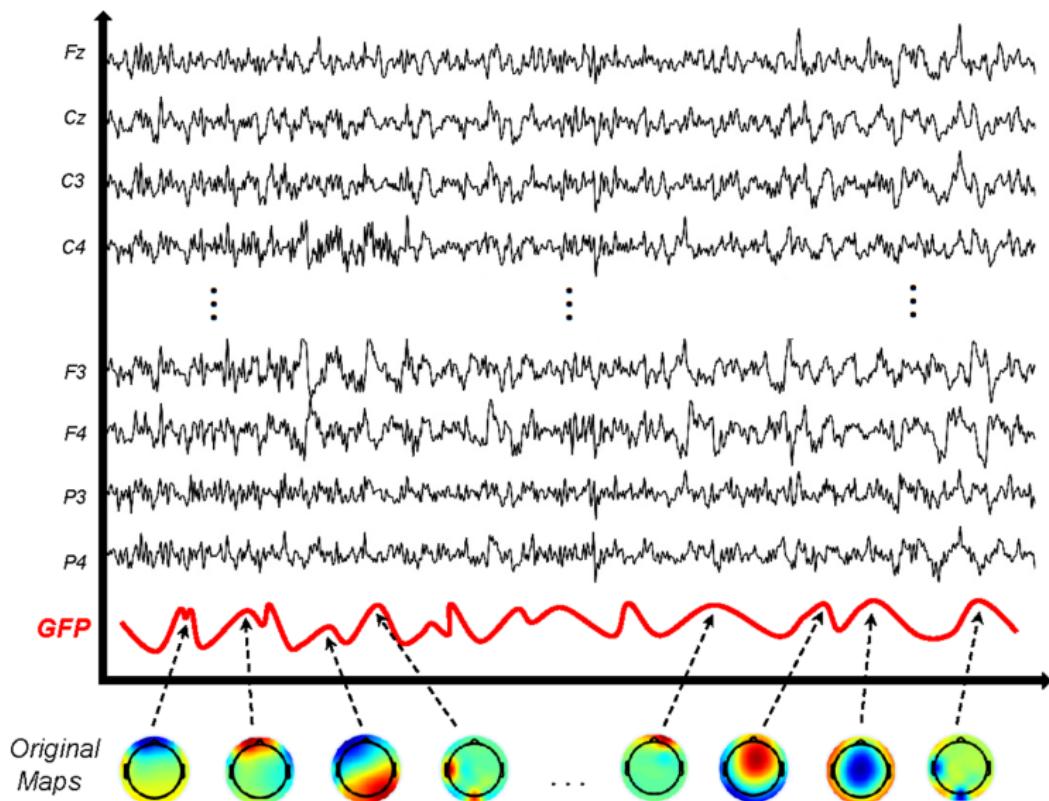
- توپوگرافی مغزی (brain topography) چیست؟

در بررسی سیگنال‌های مغزی الکتروانسفالوگرام (EEG) با قرار دادن الکترودها روی پوست سر می‌توان یک نقشه مغزی بر حسب فعالیت الکتریکی مکان‌های مختلف مغز (شکل ۲-۹) به صورت دو بعدی بدست آورد که به آن توپوگرافی مغزی گفته می‌شود. این توپوگرافی به ما در درک عملکرد مغز و تشخیص اختلالات عصبی کمک می‌کند. توپوگرافی مغز به مطالعه نقشه‌برداری از بخش‌های مختلف مغز و عملکردهای مربوط به هر بخش می‌پردازد. مغز شامل نواحی مختلفی مانند لوب پیشانی، لوب آهيانه‌ای، لوب گیجگاهی و لوب پس‌سری است که هر کدام وظایف خاصی دارند. لوب پیشانی مسئول تصمیم‌گیری، برنامه‌ریزی و کنترل حرکات است. لوب آهيانه‌ای در پردازش اطلاعات حسی مانند لمس و درد نقش دارد.



شکل ۲-۹ یک نمونه توپوگرافی از مغز [۳]

پیش‌تر گفتیم در همسایگی ماکزیمم‌های محلی (تقریباً بین دو ماکزیمم محلی)، توبوگرافی مغز ثابت است (مشخص بر روی شکل ۱۰-۲) :



شکل ۱۰-۲ توبوگرافی‌های مغز در قله GFP [۷]

اگر بخواهیم هر یک از این توبوگرافی‌ها را نماینده یک ریزحالت خاص (با ویژگی‌ها و پارامترهای خاص خودش) بدانیم قطعاً در آموزش داده‌ها دچار بیش‌بازنش (over fitting) می‌شویم جرا که در یک سیگنال GFP ما تعداد زیادی ماکزیمم محلی داریم.

بنابراین بهترین کار انتخاب تعداد محدودی دسته ریزحالت و سپس دسته‌بندی توبوگرافی‌ها است. برای انجام این کار از یک معیار ارزیابی استفاده می‌کنیم تا تعداد دسته (cluster) بهینه را بدست آورده و سپس با استفاده از روش‌های (unsupervised learning) سیگنال GFP را با انواع ریزحالت‌ها دسته بندی کنیم.

- معیار اعتبارسنجی متقابل (cross-validation criterion)

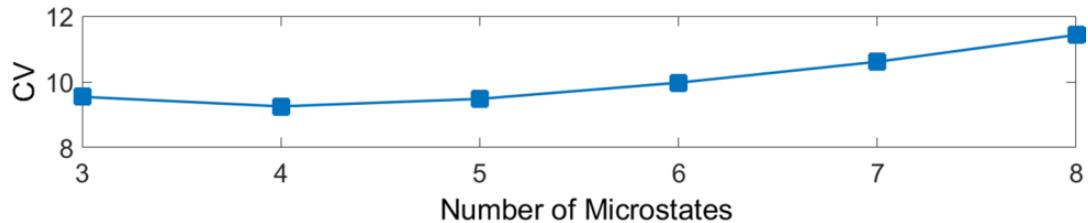
$$CV = \hat{\sigma}^2 \cdot \left(\frac{C - 1}{C - K - 1} \right)^2 \quad (2,2)$$

$$\hat{\sigma}^2 = \frac{\sum_n^N X_n^T X_n - (a_{ln}^T X_n)^2}{N(C - 1)} \quad (3,2)$$

این معیار نسبت بین واریانس گلوبال و درجات آزادی را برای مجموعه‌ای معین از نقشه‌های خوش‌های بهینه می‌کند.

در این فرمول $\hat{\sigma}^2$ یک تخمینگر واریانس نویز باقیمانده، K تعداد دسته‌ها و C تعداد الکترودها می‌باشد. در فرمول تخمینگر N تعداد نمونه‌های زمانی، بردار X_n نمونه زمانی n از سیگنال EEG است. a_{ln} نشان دهنده نقشه توپوگرافی اختصاص داده شده به نمونه n از سیگنال EEG است و l_n برچسب ریز حالت n امین نمونه سیگنال EEG است.

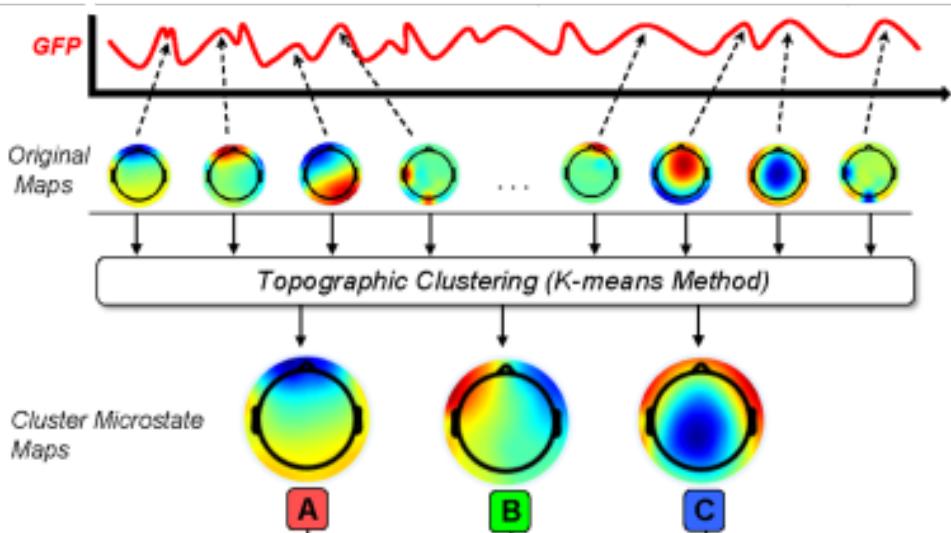
با رسم CV (شکل ۱۱-۲) به ازای k ‌های مختلف کمترین مقدار آن را انتخاب کرده و به عنوان تعداد دسته برای دسته‌بندی ریزحالت‌ها انتخاب می‌کنیم:



شکل ۱۱-۲ انتخاب تعداد cluster مناسب [۱۲]

در مقاله‌های مطالعه شده اکثراً از ۳ یا ۴ دسته ریزحالت برای طبقه بندی سیگنال اسفاده شده است ولی بطور کلی برای ریزحالت‌ها این عدد از ۳ تا ۸ متغیر است.

پس از تعیین تعداد دسته مناسب با استفاده از الگوریتم k-means (معمولاً) توپوگرافی‌های هر دسته را بدست می‌آوریم.



شکل ۲-۱۲ دسته‌های ریزحالت‌های انتخاب شده [۷]

آنچه ما تحلیل می‌کنیم GFP است، بنابراین باقی اعضای هر دسته از ریزحالت‌ها (microstates) را بر روی سیگنال برایند منطبق کنیم.
پروسه تطبیق دسته‌های ریزحالت‌ها بر روی سیگنال برایند (Back-fitting) برای انجام این کار از فرمول ریاضی GMD استفاده خواهیم کرد:

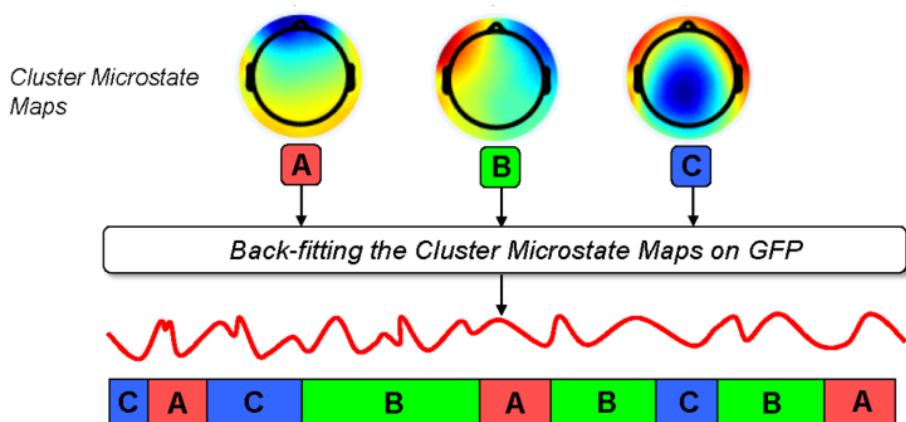
$$GMD = \frac{\| \frac{X_n}{GFPn} - \frac{X'_n}{GFPn'} \|}{\sqrt{C}} \quad (4,2)$$

X_n : این بردار نمایانگر مقادیر پتانسیل EEG در لحظه n برای یک توپوگرافی خاص می‌باشد.

X'_n : این بردار نمایانگر مقادیر پتانسیل EEG در لحظه n برای توپوگرافی global می‌باشد.

C : تعداد الکترودهای مورد استفاده در ثبت EEG است.

GMD یک اندازه گیری فاصله است که نسبت به قدرت سیگنال ثابت است و فقط به میزان شبیه بودن نقشه‌های توپوگرافی نگاه می‌کند. در نهایت با اعمال این فرمول به دسته‌بندی سیگنال GFP با استفاده از دسته‌های مختلف ریزحالت‌ها به صورت زیر می‌رسیم:



شکل ۲-۱۳ تخصیص هر بخش از سیگنال GFP به یک دسته ریزحالت [۶]

تا به اینجا ما تنها توانستیم سیگنال مغزی EEG را توسط ریزحالت‌ها دسته بندی کنیم و با ویژگی ریزحالت‌ها آن را بیان کنیم اما کار اصلی ما طبقه بندی سیگنال مغزی EEG با استفاده از ویژگی‌های تبیین شده و دیدن تفاوت‌ها است.

بنابر همین موضوع قصد داریم تعدادی پارامتر یا همان ویژگی برای ریزحالت‌ها تعریف کنیم.

- پارامترهای ریزحالت‌ها (microstate parameters (features))

با توجه به دسته‌بندی انجام گرفته از سیگنال GFP تقریباً واضح است چه پارامترهایی قابل تعریف هستند
مانند طول زمانی متوسط یک سیگنال و ...
به طور کلی پارامترهای زیر قابل تعریف هستند:

الف (Occurrence)

تعداد دسته زام ریزحالت به روی کل دسته‌های حاضر در بازه زمانی سیگنال GFP.

ب (duration)

نسبت مجموع بازه‌های زمانی دسته زام به کل دسته‌های حاضر در بازه زمانی سیگنال GFP.

پ (coverage)

نسبت مجموع بازه‌های زمانی دسته زام به کل بازه زمانی سیگنال.

ت (transition probability)

احتمال انتقال از دسته ریزحالت زام به دسته ریزحالت زام.

در ادامه با استفاده از این پارامترها به طبقه بندی می‌پردازیم.

۶.۲ طبقه بندی سیگنال‌های EEG صرعی

در اکثر مقاله‌های مورد مطالعه طبقه بندی سیگنال‌های صرعی با استفاده از دو روش می‌باشد و خواهیم دید که در مسئله طبقه بندی سیگنال‌های صرعی پارامترهای ریزحالت‌ها عملکرد مناسب و بهتری دارند.

- روش اول:

در این روش توجه به ویژگی‌های سیگنال‌های EEG معطوف است؛ به طور کلی ویژگی‌های خطی مانند میانه، میانگین، skewness و ... و ویژگی‌های غیرخطی مانند LZC، entropy،

از این ویژگی‌هایی که در مسائل دیگر برای طبقه بندی EEG استفاده می‌شود در اینجا برای طبقه بندی ریزحالت سیگنال مغزی (EEG microstate) مورد استفاده قرار می‌گیرد.

- روش دوم:

از پارامترهایی که برای ریزحالت‌ها تعریف شد به عنوان ورودی طبقه‌بند خود برای طبقه بندی استفاده می‌کنیم.

نکته مهم دیگر این است که در طبقه بندی تنها از یک طبقه‌بند (classifier) استفاده نمی‌شود بلکه از

طبقه‌بندهای مختلف مانند SVD، SVM، FLDA، MLR و ... استفاده خواهد شد و برای مقایسه طبقه‌بندها از معیارهایی مانند sensitivity، precision، accuracy و ... استفاده می‌شود. همچنین در هر مقاله تحلیل آماری نیز انجام و از p-value استفاده شده است [۷.۲].

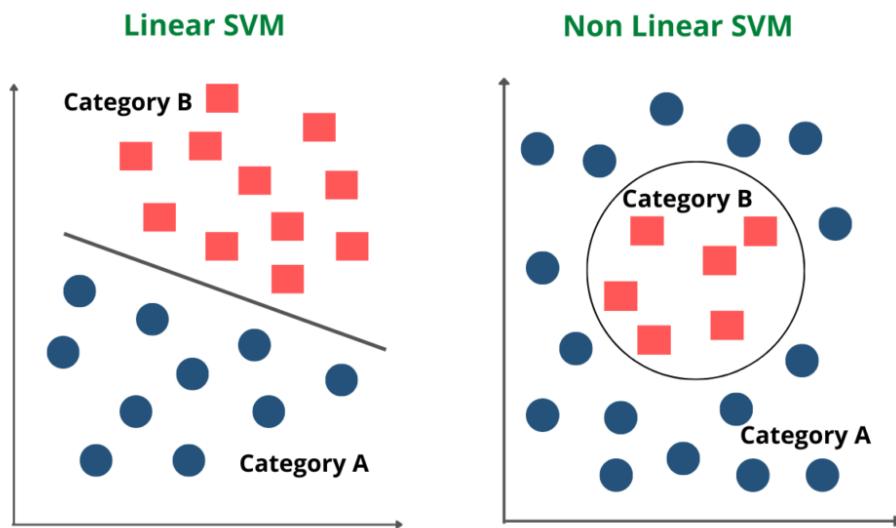
۷.۲ مفاهیم یادگیری ماشین استفاده شده

در این بخش قصد داریم به توضیح روش‌های مختلفی که برای آموزش و طبقه‌بندی داده‌ها استفاده کردہ‌ایم بپردازیم.

(الف) SVM

یکی از روش‌های طبقه‌بندی داده‌ها Support Vector Machines یا به اختصار SVM می‌باشد که یک روش supervised learning (یادگیری ناظارت شده) است.

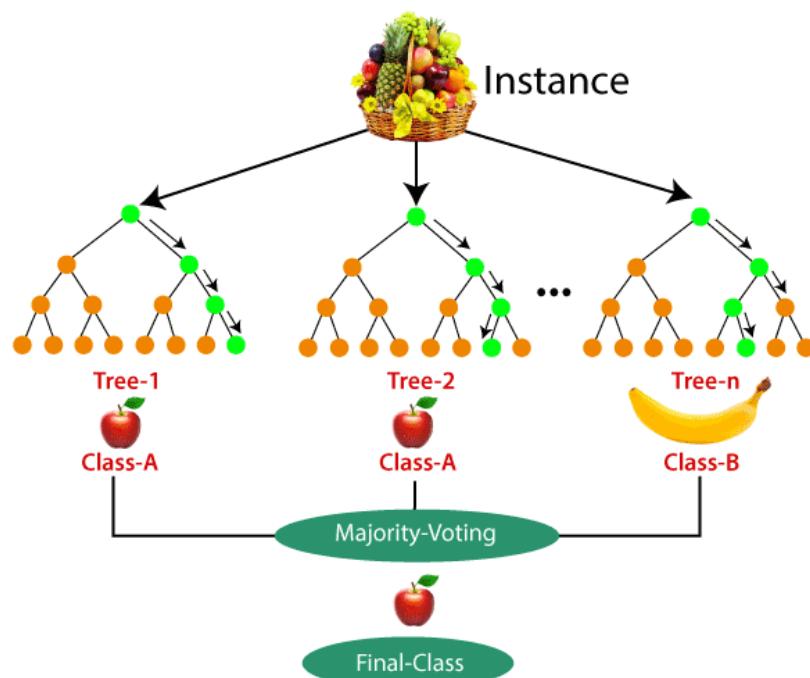
در SVM، داده‌ها در یک فضای چند بعدی قرار می‌گیرند و به گروههای مختلف تقسیم می‌شوند (شکل ۱۴-۲). SVM با ایجاد یک هایپرپلان (یک صفحه یا فضای تصمیم) که بین داده‌های مختلف قرار می‌گیرد، سعی می‌کند داده‌ها را به دسته‌بندی‌های مختلف تقسیم کند. نزدیکترین داده‌ها به هایپرپلان به عنوان وکتورهای پشتیبان (Support Vectors) شناخته می‌شوند و این وکتورها روی فراخوانی الگوریتم SVM تاثیر زیادی دارند. در هر دو حالت خطی و غیرخطی این روش عملکرد خوبی دارد که البته باید توجه کنیم در صورت بزرگ بودن داده‌ها زمان زیادی برای آموزش نیاز است.



شکل ۱۴-۲ SVM خطی و غیرخطی [۱۴]

ب) Random Forrest

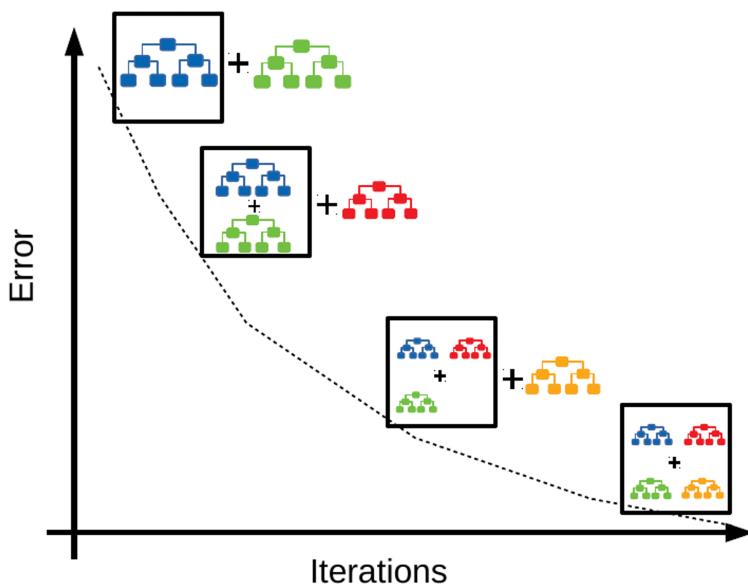
یک الگوریتم supervised learning (یادگیری با سرپرست) انعطاف‌پذیر و با استفاده آسان است که حتی بدون تنظیم بیش‌پارامتر، در اکثر مواقع نتیجه‌های عالی ایجاد می‌کند. همچنان به دلیل سادگی و تنوع یکی از پرکاربردترین الگوریتم‌ها است (هم برای کارهای طبقه‌بندی و هم برای کارهای رگرسیون قابل استفاده است). همانطور که از نام آن پیداست، Random Forest یک طبقه‌بند است که شامل تعدادی درخت تصمیم در مجموعه‌های مختلف داده‌های داده شده است و میانگین را برای بهبود دقت پیش‌بینی این مجموعه داده‌ها می‌گیرد. به جای اتکا به یک درخت تصمیم، جنگل تصادفی پیش‌بینی را از هر درخت می‌گیرد و بر اساس اکثریت رای پیش‌بینی، خروجی نهایی را پیش‌بینی می‌کند. تعداد بیشتر درختان در جنگل منجر به دقت بیشتر می‌شود و مشکل بیش‌برازش را جلوگیری می‌کند.



[۱۶] شکل ۲-۱۶ توصیف Random Forrest

پ) gradient boosting

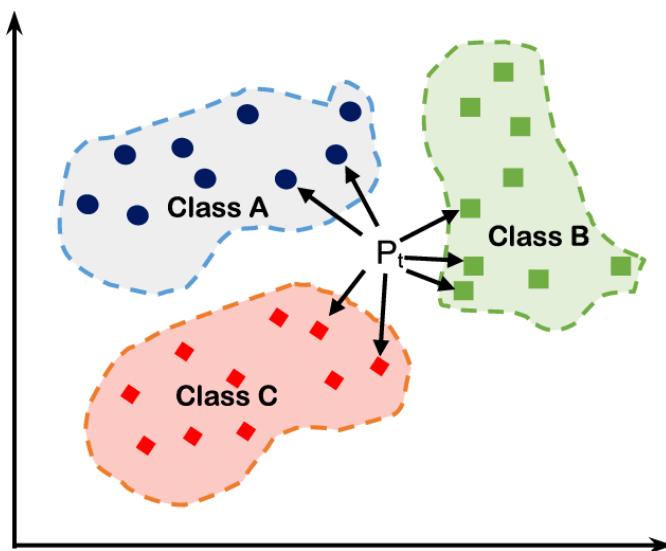
یک تکنیک مجموعه یادگیری ماشینی است که پیش‌بینی‌های چند یادگیرنده ضعیف، معمولاً درخت‌های تصمیم‌گیری را به طور متوالی ترکیب می‌کند. هدف آن بهبود عملکرد کلی پیش‌بینی با بهینه‌سازی وزن‌های مدل بر اساس خطاهای تکرارهای قبلی، کاهش تدریجی خطاهای پیش‌بینی و افزایش دقت مدل است.



شکل ۲-۱۷] gradient boosting

ت) KNN algorithm

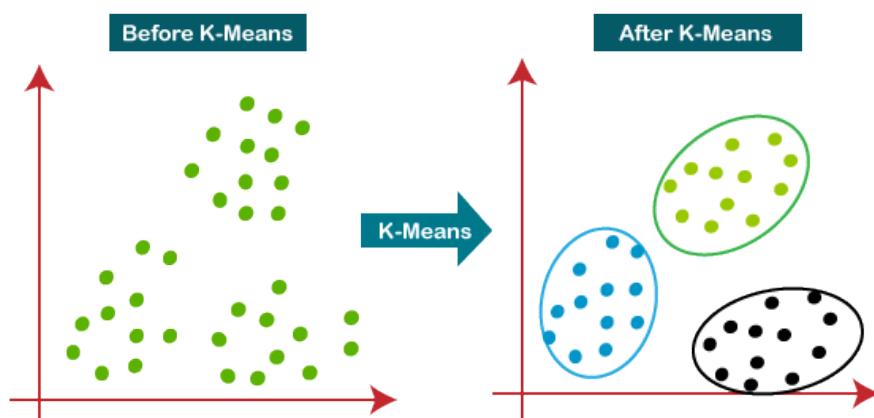
الگوریتم KNN یک الگوریتم یادگیری ماشینی همه کاره و پرکاربرد است که در درجه اول به دلیل سادگی و سهولت پیاده سازی آن استفاده می‌شود. به هیچ فرضی در مورد توزیع داده‌های اساسی نیاز ندارد. همچنین می‌تواند داده‌های عددی را مدیریت کند و آن را به انتخابی انعطاف پذیر برای انواع مختلف مجموعه داده‌ها در کارهای طبقه‌بندی و رگرسیون تبدیل می‌کند. این یک روش غیر پارامتریک است که پیش‌بینی‌هایی را بر اساس شباهت نقاط داده در یک مجموعه داده مشخص انجام می‌دهد. KNN نسبت به الگوریتم‌های دیگر حساسیت کمتری نسبت به داده‌های پرت دارد. یک الگوریتم ساده و مؤثر برای طبقه‌بندی و رگرسیون است که از نزدیک‌ترین همسایه‌ها برای پیش‌بینی استفاده می‌کند. پیاده‌سازی آن آسان بوده و بدون نیاز به آموختن، به سرعت کار می‌کند. دقت الگوریتم با افزایش حجم داده بهبود می‌یابد. اما برای داده‌های بزرگ به حافظه زیادی نیاز دارد و محاسبات زمان‌بر می‌شود. همچنین، حساسیت بالایی به ویژگی‌های بی‌اهمیت و نویز دارد. انتخاب مناسب تعداد همسایه‌ها K نیز بسیار حیاتی است.



شکل ۲-۱۸ توصیف KNN [۱۶]

ث: K-means clustering

الگوریتم K-means یک روش unsupervised learning (یادگیری بدون سرپرست) است که ابتدا یک سری مرکز را از داده‌های موجود به شکل رندوم انتخاب می‌کند با تعريف فاصله به شکل نزدیک ترین داده‌ها به هر مرکز را در یک خوش قرار می‌دهد و هر دفعه در هر دسته با کرفتن میانگین داده‌ها یک مرکز جدید انتخاب می‌کند و دوباره این کار را انجام می‌دهد تا جایی که مراکز ثابت شوند. الگوریتم ساده و سریع است و به راحتی پیاده‌سازی می‌شود. در داده‌های بزرگ با ابعاد بالا بسیار کارآمد بوده و نتایج آن به راحتی قابل تفسیر هستند. اما تعیین تعداد مناسب خوش‌ها چالش برانگیز است. نتیجه الگوریتم به مقدار دهی اولیه مراکز خوش‌ها وابسته است و ممکن است به یک مینیمم محلی همگرا شود. همچنانی فرض می‌کند خوش‌ها کروی و همگسترده هستند که همیشه صحیح نیست.

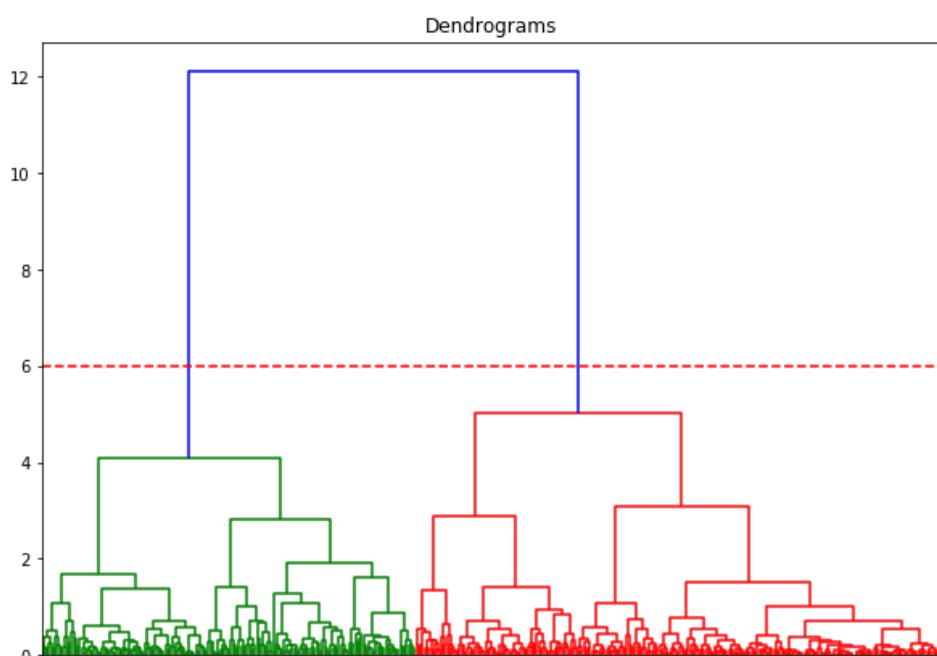


شکل ۲-۱۹ توصیف K-means [۱۵]

ج) Hierarchical clustering

یک روش دسته بندی داده‌ها است که بعد از دسته بندی داده‌ها بر اساس شباهت آن‌ها، به صورت سلسله مراتبی عمل می‌کند. در این روش، ابتدا هر نقطه به عنوان یک کلاستر جداگانه در نظر گرفته می‌شود و سپس دو کلاستری که بیشترین شباهت را دارند با یکدیگر ادغام می‌شوند. این فرآیند ادامه پیدا می‌کند و کلاسترها به تدریج تا جایی ادغام می‌شوند که تمام نقاط داده در یک کلاستر مناسب قرار گیرند.

به عنوان یکی از روش‌های کلاستر بندی، مزایایی از جمله عدم نیاز به تعداد کلاسترها مشخص از قبل و همچنین قابلیت تشکیل دندرامرها ای سلسله مراتبی دارد که می‌تواند برای دیدن ساختار داده‌ها و تحلیل شباهت و تفاوت‌های میان داده‌ها مفید باشد.



[۱۵] Hierarchical clustering

با استی اشاره کنیم این روش برای بدست آوردن تعداد بهینه خوش‌های ریزحالت‌ها شرح داده شده است.

ج) ROC curve

منحنی ROC، یا منحنی مشخصه عملکرد گیرنده، مانند نموداری است که نشان می‌دهد یک مدل طبقه‌بندی چقدر خوب عمل می‌کند. این به ما کمک می‌کند تا بینیم مدل چگونه در سطوح مختلف قطعیت تصمیم می‌گیرد. منحنی دارای دو معیار است:

یکی برای اینکه مدل چند وقت یکبار موارد مثبت را به درستی شناسایی می‌کند (مثبت‌های واقعی یا true positive) و دیگری برای اینکه چند وقت یکبار موارد منفی را به اشتباه به عنوان مثبت شناسایی می‌کند (مثبت‌های غلط یا false negative). با نگاه کردن به این نمودار، می‌توانیم درک کنیم که مدل چقدر خوب است و آستانه‌ای را انتخاب کنیم که تعادل مناسبی بین پیش‌بینی‌های درست و نادرست به ما بدهد. منحنی ROC نموداری است که به بررسی توانایی مدل در تمایز بین کلاس‌ها می‌پردازد. این منحنی رابطه بین نرخ مثبت کاذب (احتمال پیش‌بینی مثبت اشتباه) و نرخ مثبت واقعی (احتمال پیش‌بینی صحیح مثبت)

را نشان می‌دهد. محور افقی منحنی نرخ مثبت کاذب و محور عمودی آن نرخ مثبت واقعی است.

هرچه منحنی به سمت بالا و چپ نمودار نزدیک‌تر باشد، مدل عملکرد بهتری دارد.

مساحت زیر منحنی (AUC) یکی از معیارهای اصلی برای ارزیابی کیفیت مدل است که عددی بین صفر و یک است. عدد بالاتر از ۰.۵ نشان‌دهنده عملکرد بهتر از حد تصادفی است. مدل‌های با AUC نزدیک به یک بسیار خوب هستند. این منحنی به طور خاص برای ارزیابی مدل‌هایی که خروجی دوکلاسه دارند بسیار مفید است. در نهایت، منحنی ROC به انتخاب بهترین آستانه برای تصمیم‌گیری کمک می‌کند. منحنی مشخصه اپراتور گیرنده (ROC) یک معیار ارزیابی برای مسائل طبقه‌بندی بایزی است.

| | | Predicted classes | |
|----------------|---------------|-------------------|---------------|
| | | Negative 0 | Positive 1 |
| Actual classes | Negative 0 | TN | FP |
| | Positive 1 | FN | TP |

[۱۶] Confusion matrix ۲۱-۲

انواع اصطلاحاتی که برای تفسیر منحنی ROC به کار می‌رود بر اساس شکل ۲۱-۲ توضیح داده می‌شوند:

الف) AUC

یک معیار که عملکرد کلی یک مدل طبقه‌بندی بایزی را بر اساس مساحت زیر منحنی ROC نشان می‌دهد.

ب) True Positive Rate (Sensitivity - recall)
نسبت مثبت‌های واقعی که به درستی توسط مدل شناسایی شده‌اند.

$$sensitivity = \frac{TP}{TP + FN} \quad (5,2)$$

پ) False Positive Rate

مدل به اشتباه نسبت منفی‌های واقعی را به عنوان مثبت طبقه‌بندی می‌کند.

$$FPR = \frac{FP}{TN + FP} = 1 - specificity \quad (6,2)$$

ت) Specificity (True Negative Rate)

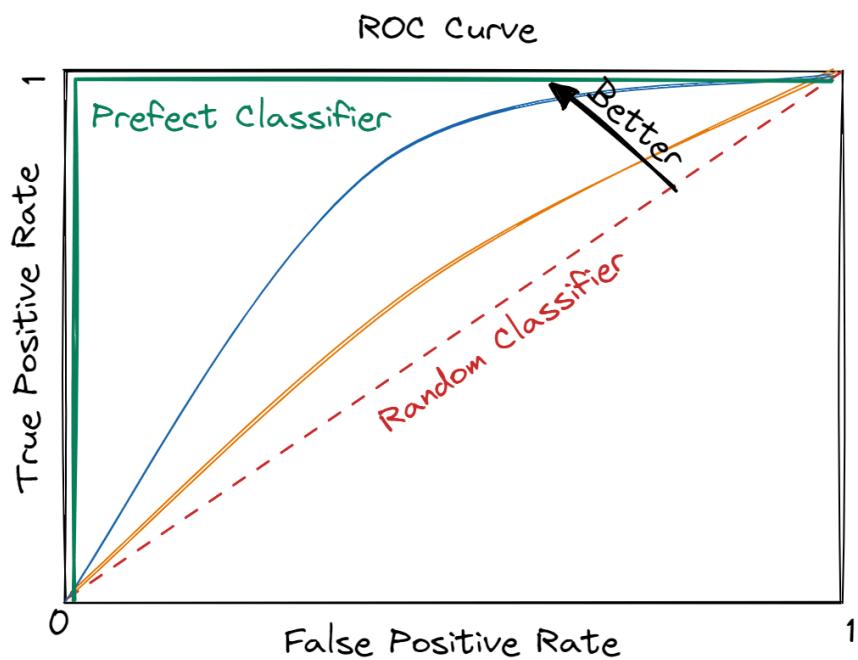
نسبت منفی‌های واقعی که به درستی توسط مدل شناسایی شده‌اند.

$$\text{specificity} = \frac{TN}{TN + FP} \quad (7, 2)$$

ث) False Negative Rate

به ما می‌گوید که چه نسبتی از کلاس مثبت طبقه بندی کننده به اشتباه طبقه بندی شده است.

$$FNR = \frac{FN}{TP + FN} \quad (8, 2)$$



شکل ۲-۲ منحنی ROC [۱۵]

۸.۲ جمع بندی

در بیان مفاهیم کلی سعی بر این بود تا موضوعات مطرح شده در مقالات و همچنین روش‌های ارائه شده را بررسی کنیم و نحوه کارکرد آن‌ها را توضیح بدھیم.

برای پردازش سیگنال‌های مغزی صرعی بیماران، بایستی پس از انجام پیش‌پردازش مناسب روی داده‌های سیگنال EEG، مسیر (pipeline) مشخصی را برای رسیدن به ریزحالات‌ها طی کنیم و پس از آن با انجام طبقه بندی مناسب عملکرد مشخصه‌های ریزحالات‌های سیگنال EEG را بسنجیم.

فصل ۳

مروری بر ادبیات

۱.۳ مقدمه

در این فصل می‌خواهیم نتایج برخی از کارهایی که تا کنون برای طبقه بندی سیگنال‌های مغزی صریعی انجام شده است را بررسی کنیم. در این بررسی ما در هر مقاله به ۵ سوال اصلی زیر را پاسخ و هرجا که نیاز بود به مفاهیم کلی موجود در فصل دوم ارجاع می‌دهیم:

(الف) پایگاه داده:

مقاله از چه داده‌هایی و در چه شرایطی برای پیشبرد هدف خود استفاده کرده است؟
ب) روش:

روش استفاده شده برای تحلیل داده‌ها چیست؟
پ) معیار ارزیابی:

خروجی‌های روش مقاله با چه معیارهایی ارزیابی و مقایسه شده‌اند؟
ت) نتایج:

نتایج کار انجام شده چیست؟

۲.۳ مقاله‌های بررسی شده در پردازش سیگنال‌های مغزی صرعی با استفاده از ریزحالت‌ها

۱.۲.۲ مقاله اول [۱]

Altered peri-seizure EEG microstate dynamics in patients with absence epilepsy

(الف) پایگاه داده:

پایگاه داده این مقاله از تحقیقی در سال‌های ۲۰۱۶ تا ۲۰۱۹ برگرفته شده است که در Hospital of Southwest Medical University با جنسیت‌های مختلف برای تشکیل پایگاه داده استفاده شده است. در این مقاله از افراد سالم و بیمار با absence epilepsy در گرفته شده است و فرکانس نمونه برداری ۲۵۶ هرتز و هر epoch ۱۰ ثانیه بوده است.

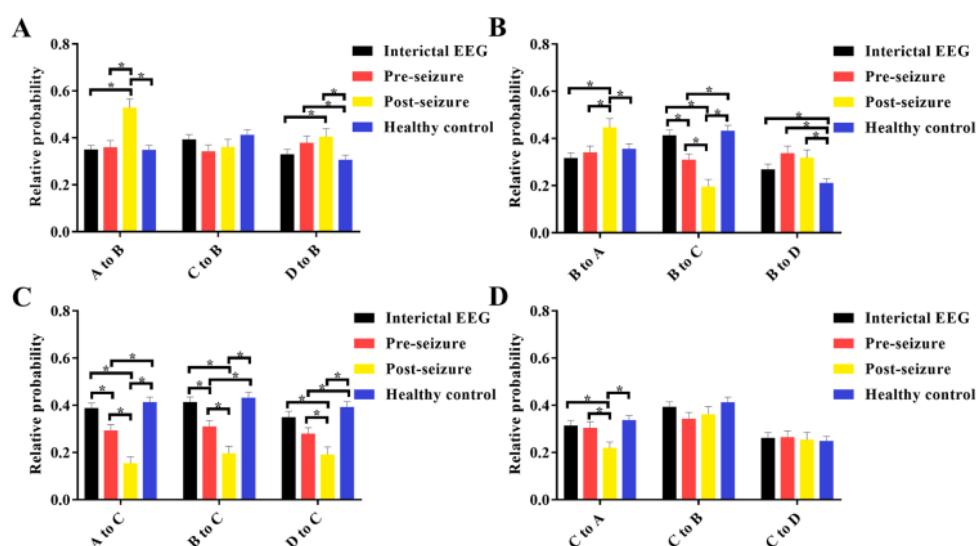
(ب) روش:

این مقاله تغییرات پارامترهای ریزحالت‌ها (بخش ۴-۵) را در فازهای مختلف سیگنال صرعی (بخش ۴-۲) بررسی کرده است و همچنین برای هر ریزحالت توپوگرافی مغز را رسم کرده و ناحیه درگیر را مشخص کرده است. همچنین ۴ دسته ریزحالت برای بررسی انتخاب شده است.

(پ) معیار ارزیابی:

نحوه تغییرات پارامترهای ریزحالت در هر فاز از سیگنال صرعی و مشاهده اختلاف تغییرات میان فازهای مختلف.

(ت) نتایج و توضیحات:



شکل ۳-۱ پارامترها در فازهای صرعی [۱]

جدول ۳-۱ تغییرات پارامترهای ریزحالت‌ها [۱]

| Microstates parameters | Pre-ictal | Post-ictal | Inter-ictal |
|------------------------|-----------|------------|-------------|
| Microstate A | | | |
| Probability A to B | — | ↗ | ↘ |
| Probability A to C | ↘ | ↘ | ↗ |
| Microstate B | | | |
| Coverage | — | — | ↗ |
| Occurrence | ↘ | — | ↗ |
| Average duration | ↗ | — | ↘ |
| Probability B to A | — | ↗ | ↘ |
| Probability B to C | ↘ | ↘ | ↗ |
| Microstate C | | | |
| Coverage | ↘ | ↘ | ↗ |
| Occurrence | ↘ | ↘ | ↗ |
| Average duration | ↗ | — | — |
| Probability C to A | — | ↘ | ↗ |
| Microstate D | | | |
| Probability D to A | — | — | ↗ |
| Probability D to B | — | — | ↘ |
| Probability D to C | — | ↘ | ↗ |

همانطور که مشاهده می‌شود (در شکل ۱-۳ و جدول ۳-۱) احتمال انتقال از ریزحالت A به ریزحالت B در بازه post-ictal برای بیماران AE بیشتر از این احتمال در بازه inter-ictal در افراد سالم است. همچنین دیگر نتایج از روی جدول و نمودارها قابل تفسیر می‌باشد.

۲.۲.۴ مقاله دوم [۲]

Intrinsic Brain Activity in Temporal Lobe Epilepsy With and Without Depression: Insights From EEG microstates

(الف) پایگاه داده:

پایگاه داده این مقاله از Beijing Tiantan Hospital در سال‌های ۲۰۱۹ تا ۲۰۲۱ از بیماران صرعی از نوع temporal lobe epilepsy و بیماران از همین نوع صرع به همراه افسردگی (depression) بدست آمده است. از هر دسته بیماران ۱۹ نفر حضور داشتند و از آنها به مدت ۷۲ ساعت سیگنال EEG با ۲۵۶ کانال و فرکانس نمونه برداری ۱۰۰۰ هرتز دریافت شده است. همچنین در تمامی سیگنال‌های کانال‌های مختلف در هر epoch ۲۰ درصد از کانال‌ها نامناسب تشخیص داده شده‌اند آنها درون‌یابی شده‌اند.

(ب) روش:

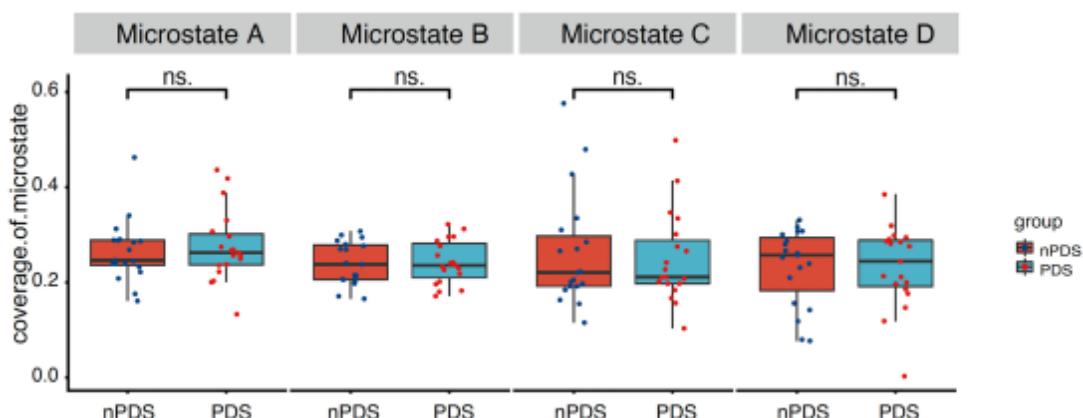
این مقاله پارامترهای ریزحالت‌ها (بخش ۲-۵) را برای هر دو گروه بیماران بررسی کرده است و همچنین این پارامترها را به عنوان ورودی به طبقه‌بند داده است. برای هر کدام p-value را نیز محاسبه کرده است.

همچنین منحنی های ROC برای دو پارامتر occurrence و duration بررسی شده است.
در ۴ دسته ریزحالتها دسته بندی شده اند.

پ) معیار ارزیابی:

مقایسه هر یک از پارامترهای ریزحالتها برای دو گروه بیماران (همچنین تحلیل آماری p-value) و بررسی منحنی های ROC برای دو پارامتر occurrence و duration انجام شده است.

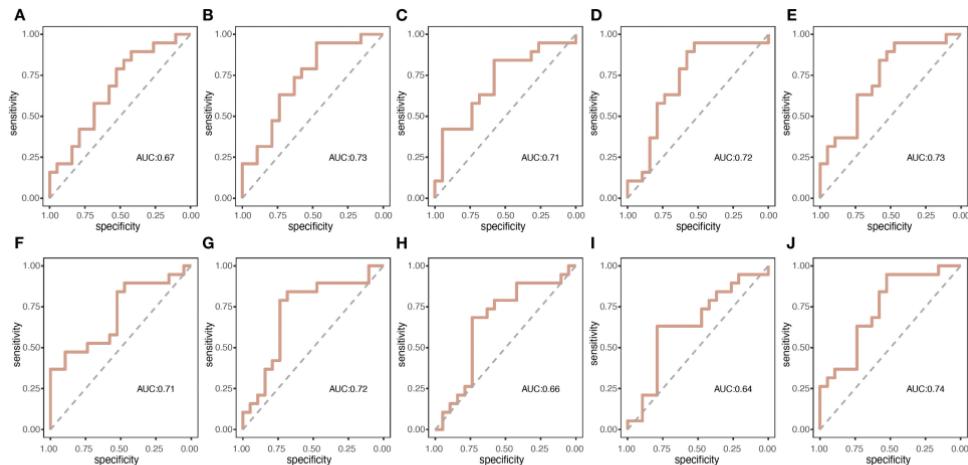
ت) نتایج و توضیحات:



شکل ۲-۳ بررسی یک پارامتر در ۴ ریزحالت [۲]

جدول ۲-۳ بررسی یک پارامتر در ۴ ریزحالت به همراه مقیاس آماری [۲]
| Occurrence per second of microstates A–D and mean of two groups.

| | PDS (<i>n</i> = 19) | nPDS (<i>n</i> = 19) | P-value |
|------|-------------------------|-------------------------|---------|
| A | 3.862 (3.418, 4,644) | 3.337 (2.738, 3.879) | 0.030 |
| B | 3.661 (3.453, 4,018) | 2.999 (2.779, 3.714) | 0.020 |
| C | 3.489 (3.066, 3,945) | 3.030 (2.642, 3,882) | 0.096 |
| D | 3.824 (3.148, 3,959) | 3.327 (2.205, 3,595) | 0.140 |
| Mean | 14.353 (13.604, 16.050) | 12.644 (11.696, 14.649) | 0.010 |



[The summary receiver operating characteristic (ROC) curves for the two groups of microstate duration and occurrence per second. (A–E) correspond to the duration of microstate map A–D and mean duration, respectively; (F–J) correspond to the occurrence per second of microstate map A–D and mean occurrence, respectively.]

شکل ۳-۲ تحلیل با ROC

همانطور که مشاهده می‌شود (براساس حدود ۲-۳) در گروه بیماران صرعی بدون افسردگی میزان occurrence و duration نسبت به بیماران صرعی به همراه افسردگی به ترتیب بیشتر و کمتر است. همچنین برای تحلیل منحنی‌های ROC (براساس شکل ۳-۲) بایستی بیان کرد که ناحیه زیر منحنی برای هر دو پارامتر duration و occurrence بیش از ۶۰٪ بودند و دو گروه از یکدیگر به خوبی قابل تشخیص هستند.

۳.۲.۴ مقاله سوم [۳]

Machine learning detects EEG microstate alterations in patients living with temporal lobe epilepsy

الف) پایگاه داده:

پایگاه داده این مقاله از ۲۱ بیمار صرعی (TLE) و ۲۱ نمونه سالم تشکیل شده است که برای هر بیمار صرعی نرخ میزان تشنج او در روزهای گذشته مشخص شده است. همچنین دیتای EEG در سیستم ۱۰-۲۰ کانال و فرکانس نمونه برداری نیز ۱۰۰۰ هرتز بوده است. همچنین برای کاهش نویز از فیلتر notch استفاده شده است.

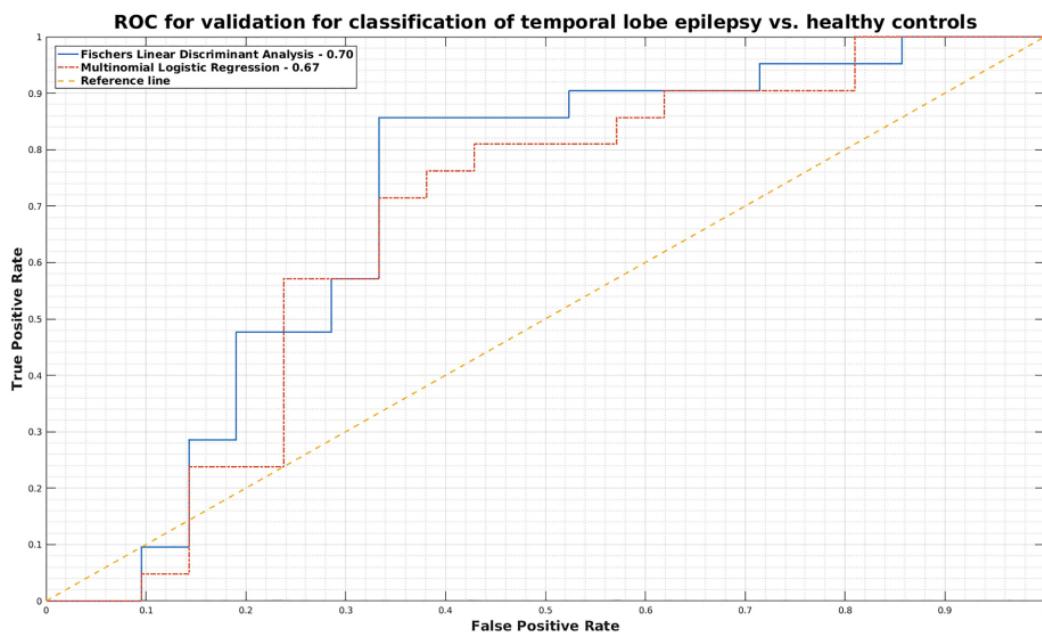
ب) روش:

این مقاله برای feature selection ابتدا داده‌های پارامترهای ریزحالت‌ها را در بازه ۰ تا ۱ نرمالایز کرده و سپس با دو classifier مختلف به طبقه‌بندی بیماران صرعی و سالم پرداخته است.

پ) معیار ارزیابی:

برای دو طبقه‌بند مختلف (MLR و FLDA) منحنی ROC رسم شده و همچنین معیارهای ارزیابی معرفی شده باهم مقایسه شده‌اند.

ت) نتایج و توضیحات:



[۳] ROC تحلیل با

با استفاده از طبقه‌بند FLDA ۳۱ و طبقه‌بند MLR ۲۸ مورد از مجموع ۴۲ مورد به درستی طبقه‌بندی شدند و دقت و حساسیت طبقه‌بند MLR بهتر بوده است (بر اساس جدول ۳-۳).

جدول ۳-۳ تحلیل و مقایسه دو طبقه بند [۳]

Performance evaluation of classifier methods.

| Sl.no | Classification method | ACC | SEN | SPC | TP | FN | FP | TN | FPR | TPR | Pres. | REC | F Measure | threshold |
|-------|-----------------------|------|------|------|----|----|----|----|------|------|-------|------|-----------|-----------|
| 1 | FLDA | 76.1 | 85.7 | 66.6 | 18 | 3 | 8 | 13 | 0.38 | 0.85 | 0.69 | 0.85 | 0.76 | 0.4998 |
| 2 | MLR | 69.0 | 80.9 | 57.1 | 17 | 4 | 9 | 12 | 0.42 | 0.80 | 0.65 | 0.80 | 0.72 | 0.4968 |

ACC → Accuracy; SEN → Sensitivity; SPC → Specificity; TP → True Positive; FN → False Negative; FP → False Positive; TN → True Negative; FPR → False Positive Rate; TPR → True Positive Rate; Pres. → Precision; REC → Recall.

۴.۲.۳ مقاله چهارم

EEG microstates analysis in patients with epilepsy

الف) پایگاه داده:

پایگاه داده این مقاله از ۶ بیمار صرعی (TLE) و ۱۰ نمونه سالم تشکیل شده است. همچنین دیتای EEG در سیستم ۲۰-۱۰ با ۱۹ کانال به مدت ۱۵ الی ۵۴ دقیقه از بیماران بدست آمده و فرکانس نمونه برداری برای بیماران صرعی و نمونه‌های سالم به ترتیب ۲۵۶ و ۱۲۸ هرتز بوده است. همچنین برای کاهش نویز و مصنوعات از فیلتر میانگذر (0.5 تا 30 هرتز) استفاده شده است.

ب) روش:

این مقاله برای کلاسترینگ ریزحالت‌ها از روش hierarchical clustering استفاده کرده است و ریزحالت‌ها را در ۴ نوع دسته‌بندی کرده است و پارامترهای ریزحالت‌ها را با پایپلاین معرفی شده (بخش ۲-۵) بدست آورده است.

پ) معیار ارزیابی:

برای مقایسه پارامترهای ریزحالت‌ها میان بیماران صرعی و نمونه‌های سالم از تحلیل آماری و دو معیار-*p* استفاده شده است. مقادیر *p-value* از روش Mann-Whitney test و median value بدست آمده است.

ت) نتایج و توضیحات:

جدول ۳-۴ میانه‌های پارامترها برای بیماران صرعی [۴]

| Median of parameters | Microstates | | | |
|----------------------|-------------|-------|-------|-------|
| | MS 1 | MS 2 | MS 3 | MS 4 |
| Duration (s) | 0.073 | 0.085 | 0.079 | 0.065 |
| Occurrence | 2.754 | 3.089 | 3.722 | 3.057 |
| Contribution | 0.218 | 0.300 | 0.284 | 0.205 |

جدول ۳-۵ میانه‌های پارامترها برای نمونه‌های سالم [۴]

| Median of parameters | Microstates | | | |
|----------------------|-------------|-------|-------|-------|
| | MS 1 | MS 2 | MS 3 | MS 4 |
| Duration (s) | 0.066 | 0.057 | 0.061 | 0.045 |
| Occurrence | 4.277 | 4.443 | 4.878 | 2.577 |
| Contribution | 0.296 | 0.249 | 0.350 | 0.110 |

جدول ۳-۶ p-value پارامترها [۴]

| Parameters | P-value | | | |
|--------------|---------|--------|--------|--------|
| | MS 1 | MS 2 | MS 3 | MS 4 |
| Duration | 0.0559 | 0.0002 | 0.1471 | 0.0002 |
| Occurrence | 0.0002 | 0.0312 | 0.0002 | 0.3676 |
| Contribution | 0.0017 | 0.0225 | 0.1806 | 0.0002 |

با توجه به جدول‌ها ریزحالت‌های ۲ و ۴ نسبت به تشنج‌های صرعی تغییرات بیشتری داشته‌اند و همچنین تفاوت زیادی در پارامتر duration بین دو گروه مشاهده شد. در ریزحالت ۳ پارامتر occurrence در مقایسه میان دو گروه تفاوت زیادی داشت.

۵.۲.۳ مقاله پنجم [۵]

EEG-based classification of epilepsy and PNES: EEG microstate and functional brain network features

(الف) پایگاه داده:

پایگاه داده این مقاله از دو گروه بیماران با تشنج صرعی (۵ نفر) و بیماران با تشنج غیرصرعی (۵ نفر) تشکیل شده است. برای بدست آوردن دیتای EEG از سیستم ۱۰-۲۰ کانال با فرکانس نمونه برداری ۲۷ هرتز انتخاب شده است و همچنین در ابتدا ۳ ساعت دیتای خام EEG موجود بوده و آن را به ۵۰ بخش (epoch) برای هر گروه تقسیم کردیم. همچنین این epoch‌ها هیچکدام شامل IED نبودند و از فیلتر میانگذر (۱ تا ۴۰ هرتز) استفاده شده است و در نهایت هر segment به sub-band‌های فرکانسی (بخش ۲-۲) تقسیم شده است.

(ب) روش:

این مقاله برای بررسی سیگنال‌های صرعی از دو روش استفاده و در نهایت آن‌ها را مقایسه کرده است. در روش اول با استفاده از ویژگی‌های سیگنال EEG که در بخش ۲-۶ بیان شد به طبقه‌بندی سیگنال‌های صرعی با طبقه‌بند متعدد و مختلف پرداخته است. همچنین با استخراج ویژگی‌های مختلف ریزحالت‌ها با استفاده از پایپلاین (بخش ۲-۵)، از آن‌ها به عنوان ورودی طبقه‌بندی‌های مختلف استفاده کرده است. در این مقاله از ۳ دسته ریزحالت برای طبقه‌بندی استفاده شده است.

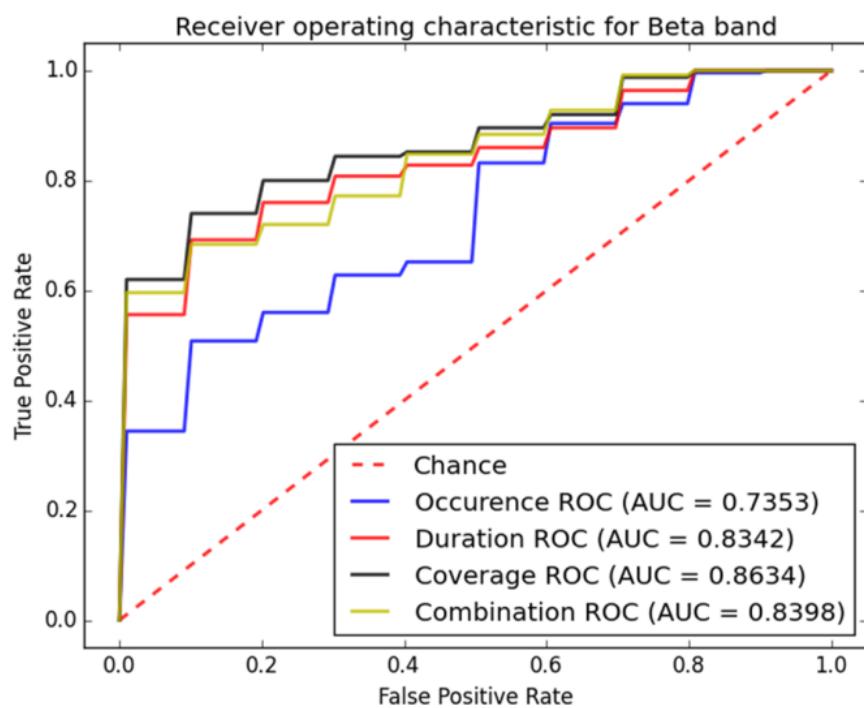
(پ) معیار ارزیابی:

همانطور که بیان شد برای مقایسه میان باندهای فرکانسی مختلف EEG از طبقه‌بندی‌های مختلف استفاده شده است و با رسم منحنی ROC و مقادیر معیارهای ارزیابی تعریف شده در مقاله قیاس میان دو گروه صورت گرفته است.

ت) نتایج و توضیحات:

جدول ۷-۳ طبقه بندی با ویژگی های سیگنال EEG (بیان شده در بخش ۲-۲) [۵]

| | Higuchi FD | Katz FD | Energy | Shanon entropy | Spectral entropy | Renyi entropy |
|---------------------------------|--------------|--------------|--------------|----------------|------------------|---------------|
| Precision, Recall at alpha-band | | | | | | |
| SVM (Linear) | 0.545, 0.438 | 0.597, 0.446 | 0.624, 0.463 | 0.655, 0.505 | 0.741, 0.639 | 0.713, 0.603 |
| SVM (RBF) | 0.422, 0.367 | 0.641, 0.483 | 0.578, 0.424 | 0.529, 0.393 | 0.742, 0.641 | 0.669, 0.559 |
| Gradient Boosting | 0.552, 0.444 | 0.582, 0.480 | 0.566, 0.474 | 0.513, 0.428 | 0.720, 0.621 | 0.692, 0.601 |
| Decision Tree | 0.514, 0.394 | 0.697, 0.616 | 0.595, 0.512 | 0.575, 0.462 | 0.616, 0.495 | 0.667, 0.568 |
| Random Forest | 0.495, 0.406 | 0.602, 0.493 | 0.524, 0.425 | 0.584, 0.438 | 0.693, 0.598 | 0.665, 0.560 |
| Precision, Recall at beta-band | | | | | | |
| SVM (Linear) | 0.601, 0.468 | 0.789, 0.677 | 0.755, 0.619 | 0.761, 0.652 | 0.743, 0.656 | 0.736, 0.651 |
| SVM (RBF) | 0.606, 0.476 | 0.754, 0.644 | 0.742, 0.597 | 0.730, 0.605 | 0.745, 0.651 | 0.774, 0.696 |
| Gradient Boosting | 0.527, 0.388 | 0.695, 0.513 | 0.646, 0.497 | 0.619, 0.474 | 0.716, 0.590 | 0.748, 0.657 |
| Decision Tree | 0.613, 0.482 | 0.695, 0.580 | 0.620, 0.483 | 0.556, 0.454 | 0.716, 0.617 | 0.706, 0.612 |
| Random Forest | 0.537, 0.433 | 0.727, 0.587 | 0.596, 0.474 | 0.685, 0.528 | 0.737, 0.637 | 0.724, 0.627 |
| Precision, Recall at delta-band | | | | | | |
| SVM (Linear) | 0.633, 0.539 | 0.703, 0.549 | 0.686, 0.539 | 0.510, 0.342 | 0.542, 0.412 | 0.557, 0.452 |
| SVM (RBF) | 0.569, 0.482 | 0.665, 0.505 | 0.683, 0.543 | 0.581, 0.432 | 0.538, 0.426 | 0.479, 0.371 |
| Gradient Boosting | 0.622, 0.519 | 0.501, 0.345 | 0.573, 0.432 | 0.534, 0.380 | 0.561, 0.477 | 0.555, 0.431 |
| Decision Tree | 0.636, 0.539 | 0.553, 0.423 | 0.592, 0.485 | 0.475, 0.384 | 0.585, 0.617 | 0.552, 0.418 |
| Random Forest | 0.558, 0.468 | 0.583, 0.468 | 0.550, 0.457 | 0.503, 0.417 | 0.515, 0.414 | 0.573, 0.465 |
| Precision, Recall at theta-band | | | | | | |
| SVM (Linear) | 0.633, 0.539 | 0.703, 0.549 | 0.686, 0.539 | 0.510, 0.342 | 0.542, 0.412 | 0.557, 0.452 |
| SVM (RBF) | 0.569, 0.482 | 0.665, 0.505 | 0.683, 0.543 | 0.581, 0.432 | 0.538, 0.426 | 0.479, 0.371 |
| Gradient Boosting | 0.622, 0.519 | 0.501, 0.345 | 0.573, 0.431 | 0.534, 0.380 | 0.561, 0.477 | 0.555, 0.431 |
| Decision Tree | 0.636, 0.539 | 0.553, 0.423 | 0.592, 0.485 | 0.475, 0.384 | 0.585, 0.617 | 0.552, 0.418 |
| Random Forest | 0.558, 0.468 | 0.583, 0.468 | 0.550, 0.457 | 0.503, 0.417 | 0.515, 0.414 | 0.573, 0.465 |
| Precision, Recall at gamma-band | | | | | | |
| SVM (Linear) | 0.331, 0.251 | 0.583, 0.470 | 0.724, 0.552 | 0.539, 0.432 | 0.539, 0.340 | 0.537, 0.390 |
| SVM (RBF) | 0.409, 0.324 | 0.632, 0.481 | 0.686, 0.501 | 0.642, 0.501 | 0.501, 0.346 | 0.501, 0.389 |
| Gradient Boosting | 0.382, 0.317 | 0.743, 0.651 | 0.556, 0.442 | 0.488, 0.406 | 0.488, 0.368 | 0.525, 0.403 |
| Decision Tree | 0.468, 0.369 | 0.761, 0.650 | 0.550, 0.481 | 0.559, 0.478 | 0.505, 0.361 | 0.548, 0.420 |
| Random Forest | 0.381, 0.353 | 0.632, 0.490 | 0.613, 0.537 | 0.578, 0.462 | 0.524, 0.415 | 0.523, 0.419 |



شکل ۳-۵ منحنی ROC در باند بتا [۵]

جدول ۸-۳ طبقه بندی با پارامترهای ریزحالت‌ها EEG (بیان شده در بخش ۲-۵) [۵]

| | All | All-alpha | All-beta | All-delta | All-theta |
|--|----------------------|---------------------|---------------------|---------------------|----------------------|
| Accuracy, Precision, Recall using occurrence (k) as the discriminative (input) feature | | | | | |
| Random Forest | 0.696, 0.732, 0.696 | 0.700, 0.738, 0.700 | 0.536, 0.537, 0.536 | 0.708, 0.741, 0.708 | 0.734, 0.784, 0.734 |
| SVM (Linear) | 0.732, 0.758, 0.732 | 0.734, 0.768, 0.734 | 0.396, 0.391, 0.396 | 0.724, 0.756, 0.724 | 0.700, 0.725, 0.700 |
| SVM (RBF) | 0.730, 0.774, 0.730 | 0.724, 0.772, 0.724 | 0.524, 0.535, 0.524 | 0.728, 0.772, 0.728 | 0.758, 0.793, 0.758 |
| Decision Tree | 0.646, 0.683, 0.646 | 0.680, 0.711, 0.680 | 0.602, 0.615, 0.602 | 0.656, 0.682, 0.656 | 0.680, 0.715, 0.680 |
| kNN | 0.794, 0.814, 0.794 | 0.822, 0.841, 0.822 | 0.694, 0.708, 0.694 | 0.762, 0.788, 0.762 | 0.802, 0.831, 0.802 |
| Gradient Boost | 0.692, 0.729, 0.692 | 0.696, 0.746, 0.696 | 0.654, 0.669, 0.654 | 0.688, 0.732, 0.688 | 0.698, 0.731, 0.698 |
| Accuracy, Precision, Recall using duration (k) as the discriminative (input) feature | | | | | |
| Random Forest | 0.686, 0.735, 0.686 | 0.684, 0.741, 0.684 | 0.538, 0.544, 0.538 | 0.674, 0.747, 0.674 | 0.670, 0.731, 0.670 |
| SVM (Linear) | 0.690, 0.740, 0.690 | 0.740, 0.806, 0.740 | 0.464, 0.401, 0.464 | 0.614, 0.668, 0.614 | 0.662, 0.733, 0.662 |
| SVM (RBF) | 0.614, 0.758, 0.614 | 0.590, 0.713, 0.590 | 0.598, 0.623, 0.598 | 0.694, 0.716, 0.694 | 0.578, 0.678, 0.578 |
| Decision Tree | 0.662, 0.685, 0.662 | 0.718, 0.743, 0.718 | 0.584, 0.587, 0.584 | 0.730, 0.758, 0.730 | 0.644, 0.668, 0.644 |
| kNN | 0.724, 0.746, 0.724 | 0.744, 0.773, 0.744 | 0.530, 0.541, 0.530 | 0.776, 0.820, 0.776 | 0.740, 0.765, 0.740 |
| Gradient Boost | 0.754, 0.796, 0.754 | 0.772, 0.810, 0.772 | 0.632, 0.636, 0.632 | 0.722, 0.767, 0.722 | 0.710, 0.743, 0.710 |
| Accuracy, Precision, Recall using coverage (k) as the discriminative (input) feature | | | | | |
| Random Forest | 0.730, 0.776, 0.730 | 0.734, 0.782, 0.734 | 0.560, 0.567, 0.560 | 0.710, 0.769, 0.710 | 0.754, 0.794, 0.754 |
| SVM (Linear) | 0.674, 0.702, 0.674 | 0.664, 0.696, 0.664 | 0.460, 0.439, 0.460 | 0.672, 0.707, 0.672 | 0.672, 0.704, 0.672 |
| SVM (RBF) | 0.618, 0.6631, 0.618 | 0.620, 0.666, 0.620 | 0.380, 0.354, 0.380 | 0.634, 0.681, 0.634 | 0.616, 0.656, 0.616 |
| Decision Tree | 0.698, 0.711, 0.698 | 0.738, 0.753, 0.738 | 0.682, 0.692, 0.682 | 0.678, 0.704, 0.678 | 0.628, 0.661, 0.628 |
| kNN | 0.776, 0.806, 0.776 | 0.764, 0.786, 0.764 | 0.634, 0.644, 0.634 | 0.778, 0.802, 0.778 | 0.738, 0.784, 0.738 |
| Gradient Boost | 0.762, 0.804, 0.762 | 0.782, 0.815, 0.782 | 0.696, 0.707, 0.696 | 0.758, 0.797, 0.758 | 0.748, 0.792, 0.748 |
| Accuracy, Precision, Recall using combination of occurrence (k), duration (k) and coverage (k) as the discriminative (input) feature | | | | | |
| Random Forest | 0.678, 0.738, 0.678 | 0.698, 0.764, 0.698 | 0.562, 0.567, 0.562 | 0.688, 0.757, 0.688 | 0.710, 0.779, 0.710 |
| SVM (Linear) | 0.712, 0.753, 0.712 | 0.734, 0.792, 0.734 | 0.514, 0.488, 0.514 | 0.612, 0.634, 0.612 | 0.656, 0.742, 0.656 |
| SVM (RBF) | 0.530, 0.337, 0.530 | 0.500, 0.250, 0.500 | 0.494, 0.308, 0.494 | 0.514, 0.393, 0.514 | 0.508, 0.268, 0.508 |
| Decision Tree | 0.692, 0.725, 0.692 | 0.698, 0.719, 0.698 | 0.612, 0.624, 0.612 | 0.660, 0.690, 0.660 | 0.646, 0.678, 0.646 |
| kNN | 0.724, 0.746, 0.724 | 0.744, 0.773, 0.744 | 0.530, 0.540, 0.530 | 0.776, 0.820, 0.776 | 0.740, 0.7652, 0.740 |
| Gradient Boost | 0.754, 0.792, 0.754 | 0.772, 0.805, 0.772 | 0.702, 0.712, 0.702 | 0.714, 0.763, 0.714 | 0.758, 0.786, 0.758 |

یکی از مشکلاتی که در تشخیص تشنج‌های صرعی از تشنج‌های غیرصرعی وجود دارد وجود IED‌ها می‌باشد بدین صورت که اگر در تشنج صرعی مشخصه IED وجود نداشته باشد در اکثر اوقات تشنج غیرصرعی (PNES) تشخیص داده می‌شود.

این مقاله با استفاده از تحلیل ریزحالت‌ها توانست دو گروه را در باند فرکانسی بتا به خوبی طبقه بندی کند؛ اما در طبقه بندی با استفاده از ویژگی‌های سیگنال EEG طبقه بندی مشخص و مناسی شکل نمی‌گیرد و باند گاما با دقت کمی بهترین طبقه‌بندی و باند تتا بدترین طبقه‌بندی را داشته است.

۶.۲.۳ مقاله ششم [۶]

EEG Microstate Features as an Automatic Recognition Model of High-Density Epileptic EEG Using Support Vector Machine

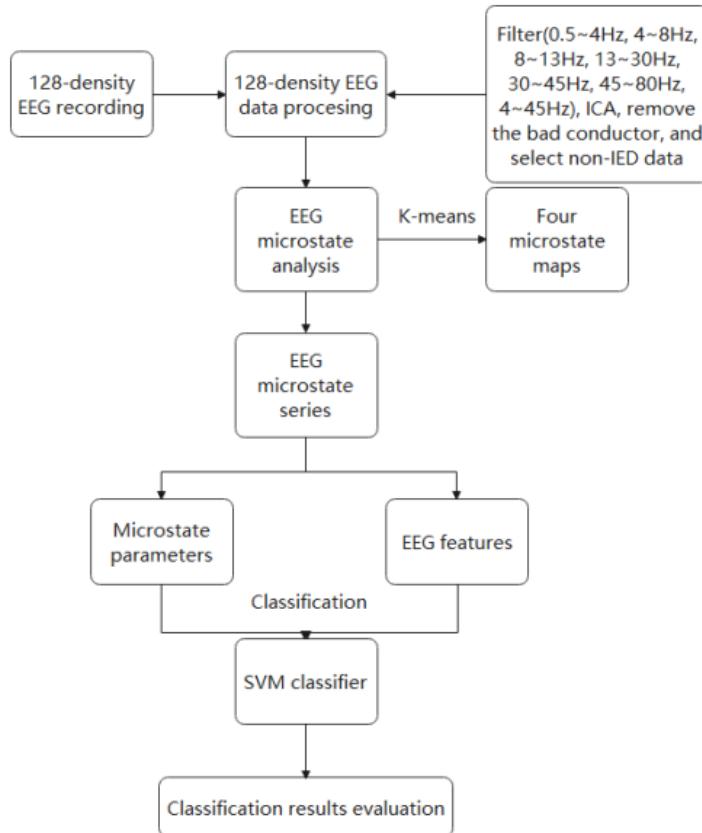
(الف) پایگاه داده:

پایگاه داده این مقاله شامل ۴۴ شرکت کننده (۲۷ بیمار صرعی و ۱۷ نمونه سالم) می‌باشد که با استفاده از فیلتر ابتدا سیگنال EEG را به زیرکانال‌های خود تقسیم کرده و سپس با استفاده از فیلتر ICA کانال‌های بد را حذف و دیتابیسی که شامل IED نمی‌باشد را انتخاب کرده است.

(ب) روش:

این از ۱۲۸ الکترود برای ضبط EEG استفاده کرده و برای بررسی سیگنال‌های صرعی مدلی را معرفی می‌کند که براساس این مدل ابتدا ریزحالت‌ها را استخراج و دسته بنديمی‌کند که پيش‌تر توضیح داده شد. سپس برای انتخاب ورودی‌های طبقه بند از دو روش استفاده می‌کند. روش اول بر اساس ویژگی‌های سیگنال و

روش دوم بر اساس پارامترهای تعریف شده برای ریزحالت‌ها است که در فصل مفاهیم کلی به آن اشاره شد [۵-۲]. این مقاله از طبقه‌بند SVM برای طبقه‌بندی استفاده کرده است. این مقاله ریزحالت‌ها را در ۴ دسته تقسیم بندی کرده است.

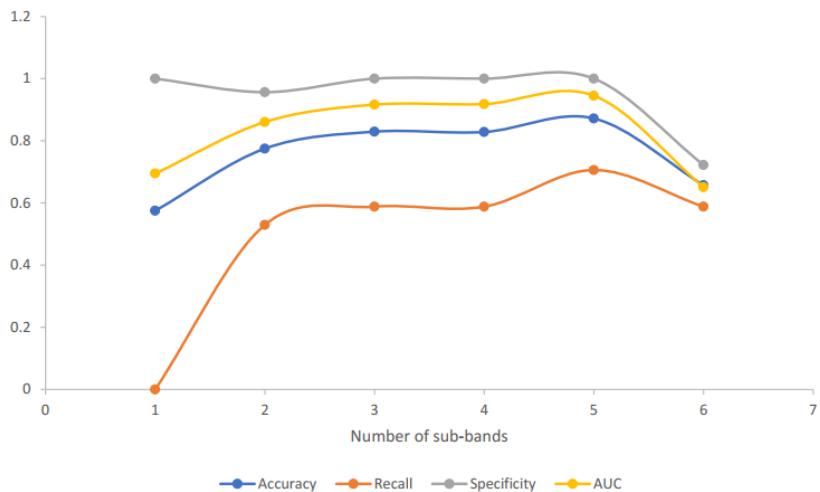


شکل ۳-۶ پایپلاین مقاله برای طبقه‌بندی سیگنال مغزی صرعی [۶]

پ) معیار ارزیابی:

معیار ارزیابی این مقاله بررسی نمودار ROC و مشتقات بدست آمده از آن بوده است که برای دو روش استخراج ویژگی بدست آمده است.

ت) نتایج و توضیحات:



شکل ۷-۳ ارزیابی [۶]

جدول ۹-۳ ارزیابی روش اول [۶]

| Number | Sub-Band | Accuracy | Recall | Specificity | AUC |
|--------|---------------------|----------|--------|-------------|--------|
| 1 | δ (0.5~4 Hz) | 0.5750 | 0 | 1 | 0.6947 |
| 2 | θ (4~8 Hz) | 0.7750 | 0.5294 | 0.9565 | 0.8605 |
| 3 | α (8~13 Hz) | 0.8293 | 0.5882 | 1 | 0.9165 |
| 4 | β (13~30 Hz) | 0.8283 | 0.5882 | 1 | 0.9182 |
| 5 | γ (30~45 Hz) | 0.8718 | 0.7059 | 1 | 0.9452 |
| 6 | 45~80 Hz | 0.6571 | 0.5882 | 0.7222 | 0.6508 |

جدول ۱۰-۳ ارزیابی روش دوم [۶]

| EEG Signal Features Set | Classification Accuracy (%) | Recall (%) | Specificity (%) |
|--|-----------------------------|------------|-----------------|
| Median, second quartile, mean, kurtosis, skewness, fuzzy entropy, PFD, ApEn, SampEn, LZC | 79.55 | 81.84 | 76.47 |

در این مقاله مشاهده شد که بیشترین دقیق طبقه بند در باند گاما بوده است.

۳.۳ مقاله‌های بررسی شده در پردازش سیگنال‌های مغزی صرعی بدون ریزحالت‌ها

[۷] ۱.۳.۳ مقاله اول

Epileptic Seizures Prediction Using Machine Learning Methods

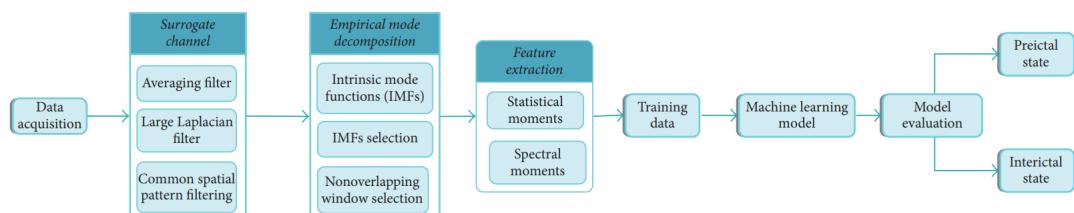
الف) پایگاه داده:

این مقاله از پایگاه داده معروف CHB-MIT استفاده کرده است که شامل ۲۲ نمونه و EEG با ۲۳ کanal گردآوری شده است.

در پیش پردازش این سیگنال در دو مرحله انجام گرفته است که در مرحله اول تمامی ۲۳ کanal به یک surrogate channel تبدیل شده است و در مرحله دوم برای افزایش بیشتر SNR از EMD استفاده شده است.

ب) روش:

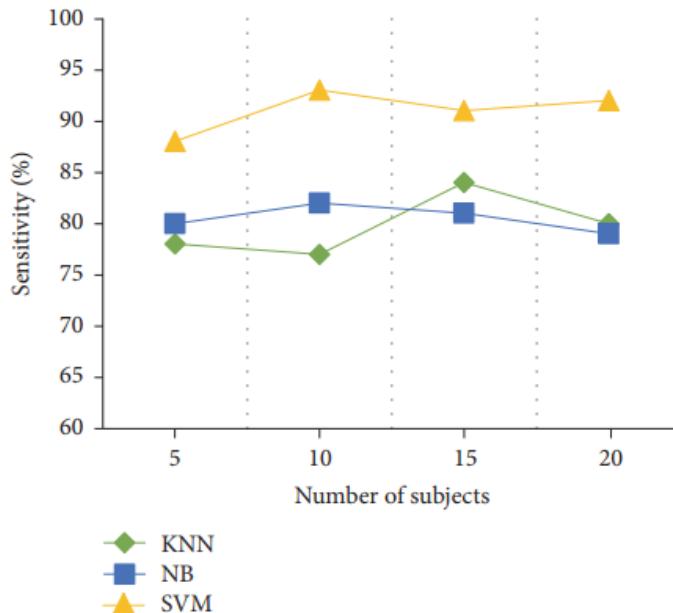
این مقاله برای پیشینی صرع از پایپلاین استفاده کرده است:



شکل ۸-۳ پایپلاین پیشینی صرع [۷]

این مقاله از ویژگی‌های سیگنال EEG برای طبقه‌بندی استفاده کرده است. البته این مقاله ادامه یک کار دیگر توسط همین نویسندهان بوده که در کارهای قبلی از ۲ مدل مختلف استفاده شده و این مقاله مبتنی بر همان مدل‌ها و مدل جدید خود proposed model که در قسمت (معیار ارزیابی - بخش ۴.۴) خواهد آمد طبقه‌بندی را انجام داده است.

در روش جدید این مقاله تصمیم گرفته است که پس از SVM به دلیل حساسیت بالاتر برای طبقه‌بندی استفاده کند:

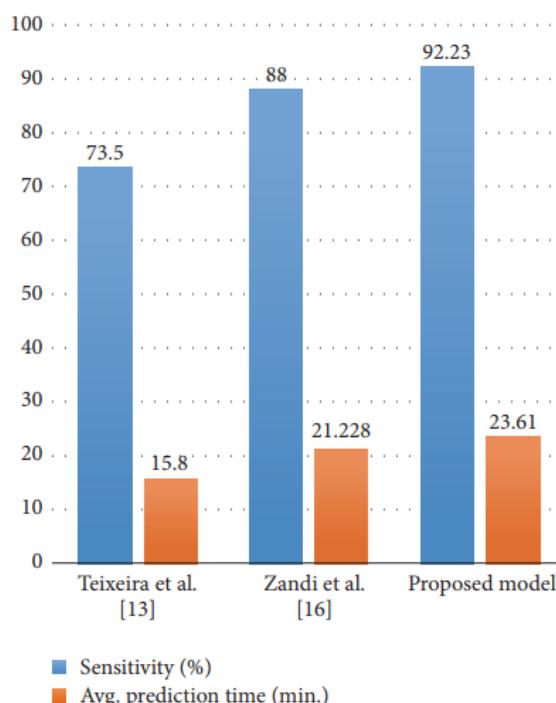


شکل ۹-۳ روش‌های مورد استفاده [۷]

پ) معیار ارزیابی:

معیار ارزیابی این مقاله مقایسه دقت و حساسیت مدل‌های پیشین طراحی شده و مدل جدید است. همچنین مقایسه میان زمان پیشینی تشنج قبل از وقوع نیز توسط این ۳ مقاله انجام شده است.

ت) نتایج و توضیحات:



شکل ۱۰-۳ مقایسه میان مدل جدید مقاله و مدل‌های قبلی [۷]

این مقاله در مقایسه با مدل‌های قبلی خود توانسته مدت زمان پیشینی وقوع صرع را افزایش داده و حدود

۶۱.۲۳ دقیقه قبل از وقوع صرع آن را پیشینی کند (شکل ۳-۱۰). همچنین این مقاله قصد دارد مدل جدیدی را در آینده با حساسیت بالاتر معرفی کند.

۲.۳.۳ مقاله دوم [۸]

Spike-microstates correlate with interictal epileptogenic discharges: a marker for hidden epileptic activity

(الف) پایگاه داده:

پایگاه داده این مقاله شامل ۱۸ بیمار از ۳ دسته مختلف بیماران صرعی است و از فیلتر میانگذر ۱ تا ۷۰ هرتز و فیلتر notch ۵۰ هرتز برای کاهش نویز استفاده شده است.

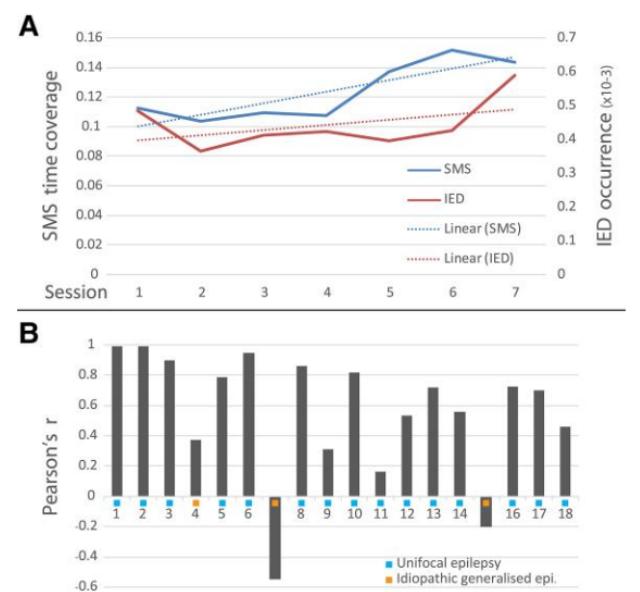
(ب) روش:

این مقاله با تمرکز بر روی استخراج IED و میزان وقوع آن در انواع مختلف صرع به انجام پردازش ریزحالت‌ها پرداخته است و تاثیر داروهای مختلف را بر روی IED بررسی شده است. هر IED در سیگنال هر بیمار مشخص شده و توپوگرافی پیک‌های تمام IED‌ها میانگین گرفته شده است سپس برای هر فرد یک Backfitt (average spike topography) AST کردیم که منجر به تولید SMS یا همان Spike-microstate شد. حضور SMS در باقی مانده سیگنال نسبت به سیگنال‌های هر بسته شامل IED با میزان رخداد IED در کل سیگنال و همچنین دوز داروی مصرفی ارتباط دارد.

(پ) معیار ارزیابی:

ضریب همبستگی پیرسون و نمودار IED و SMS (شکل ۳-۱۱).

ت) نتایج و توضیحات:



شکل ۱۱-۳ نمودارهای SMS و IED

قابل ذکر است که میانگین پوشش زمانی SMS بطور قابل توجهی بیشتر از فرکانس IED است. به عبارت دیگر، برای یک IED ما به طور متوسط SMS ۲۶۲ مشاهده می‌کنیم (بر اساس شکل ۱۱-۳) که SMS را به یک نشانگر مناسب در مقایسه با IED تبدیل می‌کند.

۴.۲ جمع بندی

همانطور که در بررسی مقاله‌ها دیدیدم به طور کلی بررسی سیگنال‌های مغزی صرعی به دو روش با استفاده از ریزحالت‌ها و ویژگی‌های سیگنال صورت می‌گیرد و نتایج این مقاله‌ها از دقت بالای پارامترهای ریزحالت‌ها برای طبقه بندی خبر می‌دهند. همچنین در پردازش ریزحالت‌ها، پیش پردازش سیگنال‌های مغزی می‌تواند حائز اهمیت باشد.

در مقاله‌های مختلف طبقه بندی مورد نظر روی پایگاه داده‌های متفاوتی صورت گرفته و طبقه بندی با دقت بالا در مقایسه دو گروه بیماران تشنجی (صرعی و غیرصرعی یا ...) نشان از کارآمد بودن پارامترهای ریزحالت‌ها در طبقه بندی دارند.

فصل ۴

پیاده سازی

۱.۴ مقدمه

در این فصل سعی شده است آن چه را پیشتر به تفصیل شرح دادیم پیاده سازی کرده و به نتایج معتبری دست پیدا کنیم. پس از بررسی مقاله‌های مختلف و روش‌های مورد استفاده؛ پیاده سازی بر اساس روش‌های متداول و منتج به خروجی معترض پیش برد شد. در فرایند پیاده سازی به دلیل نوین بودن کار به چالش‌های مختلفی برخورد کردیم که در نهایت با جستجوهای فراوان و مطالعه مقاله‌های بیشتر آن‌ها مرتفع شدند. در ادامه جزئیات پیاده سازی تشریح خواهد شد.

۲.۴ پایگاه داده

در پیاده سازی پیش رو از پایگاه داده‌ای با جزئیات جدول ۱-۴ استفاده استفاده شده است. در این پایگاه داده افراد بیمار مبتلا به اسکیزوفرنی بوده‌اند [۲۰].

جدول ۱-۴ اطلاعات پایگاه داده مورد استفاده

| پایگاه داده | |
|-------------|------------------------------------|
| ۱۴ نفر | افراد سالم |
| ۱۴ نفر | افراد بیمار |
| ۸۴۰ ثانیه | میانگین زمان نمونه برداری هر نمونه |
| ۲۵۰ هرتز | فرکانس نمونه برداری |
| ۲۰-۱۰ | سیستم نمونه برداری EEG |
| Cz و Fz بین | الکترود مرجع |
| ۱۹ | تعداد الکترود |

۳.۴ روش

۱.۳.۴ پیش پردازش

در انتخاب روش مناسب برای پیاده سازی بایستی به مسائل مختلفی توجه شود که پیشتر در مورد آن در هر مقاله به کرات صحبت شد. داده مورد استفاده به ترتیب مراحل زیر پیش پردازش شد (با استفاده از ابزار : MATLAB (EEGLAB

الف) قرار دادن مرجع (Re-Referencing)

از روش متداول قراردهی مقدار میانگین الکتروودها به عنوان مرجع استفاده شد.

ب) استفاده از فیلتر میان گذر (۲۰-۲ هرتز):

با استفاده از Basic FIR Filter

پ) قطعه بندی ۵ ثانیه‌ای داده (Epoching):

با استفاده از Extract Epochs

پ) حذف نویز حرکتی-ماهیچه‌ای (artefact rejection):

با استفاده از remove epochs from baseline و استفاده از معیار واریانس. پس از انجام این پیش پردازش داده‌های ۱۴ نفر سالم به ۲۱۵۰ epoch و داده‌های ۱۴ نفر بیمار به ۱۹۱۲ epoch قطعه بندی شد.

۲.۳.۴ محاسبه Global Field Power

به طور کلی تحلیل‌های ریزحالت‌ها را در ادامه با استفاده از ابزار microstate+ انجام شده که در هر بخش روند کل آن توضیح داده شده است.

در این بخش بر اساس فرمول (۱،۲) برای هر فرد سیگنال GFP با استفاده از تابع calculate_gfp محاسبه شده است. در این تابع دقیقاً انحراف معیار الکتروودها در هر لحظه زمانی محاسبه می‌گردد. این فرمول بر روی کل بازه دیتای هر نمونه (subject) محاسبه شده است.

۳.۳.۴ خوشه بندی بهینه سیگنال (Clustering)

همانطور که در معیار اعتبارسنجی متقابل (cross-validation criterion) (بخش ۲-۲) بیان شد در اینجا برای هر فرد تعداد بهینه خوشه محاسبه شد. البته در پیاده سازی برای تمامی افراد تعداد خوشه بهینه یکسانی بدست نیامد اما طبق مطالعات می‌توان با دقت خوبی بیشترین تکرار در تعداد خوشه بهینه را به عنوان مرجعی برای افراد هر کلاس از داده (بیمار و سالم) در نظر گرفت (طبق جدول (۲-۴)).

برای پیاده سازی این بخش از تابع cluster_koptimum استفاده شد؛ این تابع علاوه بر تعداد خوشه بهینه اطلاعات مورد نیاز دیگر را نیز، که در ادامه به آن‌ها اشاره خواهد شد، در اختیار ما قرار می‌دهد. برای رسم توپوگرافی هر خوشه نیز از خروجی‌های همین دستور استفاده شده است.

البته معیار GEV نیز قابل استفاده است اما از آنچایی که اکثر مقاله‌ها از معیار CV در بحث طبقه بندی استفاده کرده‌اند من نیز از این معیار استفاده کردم.

۴.۳.۴ تطبیق خوشها بر روی (GFP)

تابعی که پیشتر برای بدست آوردن بهینه خوشها بیان شد در ورودی از ما بازه‌ای را برای بدست آوردن تعداد خوشها بهینه می‌گیرد و در آن بازه بر اساس معیار CV بهینه خوشها را بر می‌گرداند. البته با استی اشاره نماییم این تابع بدون توجه به تعداد خوشها بهینه تمامی تطبیق‌ها را بر اساس خوشها مختلف حساب کرده و ذخیره می‌کند که این مسئله با توجه به عدم قطعیت پاسخ خوشها برای ریزحالت‌ها کارآمد می‌باشد. در این تابع از فرمول GMD (فرمول ۴-۲) استفاده شده است که تقریباً تمامی مقاله‌ها از این معیار برای تطبیق استفاده کرده‌اند.

۵.۳.۴ طبقه بندی

در این قسمت با استفاده از دو طبقه بند SVM و MLP داده‌ها را طبقه بندی کردیم. در طبقه بندی داده‌های دو کلاس (افراد سالم و بیمار) را مخلوط کرده و ۸۰ درصد را به عنوان داده آموزش و ۲۰ درصد را به عنوان داده امتحان در نظر گرفتیم (برای ویژگی‌های conventional K-Fold Cross-Validation به ازای $K = 5$ تقسیم کرده و در نهایت میانگین Accuracy آنها ذکر شده است اما برای ویژگی‌های ریزحالت‌ها طبقه بندی فقط برای یک بار جداسازی داد به داده آموزش و تست انجام شده است). ویژگی‌های طبقه بند نیز از سه دسته ویژگی قابل تمایز برای سیگنال‌ها یعنی زمانی، فرکانسی و آماری انتخاب شد که من برای پیاده سازی از ویژگی‌های زیر استفاده کرده‌ام:

- میانگین
- واریانس
- چولگی

- توان مجموع با استفاده از PSD
- انتروپی شنون

علاوه بر این سه ویژگی برای طبقه بندی از پارامترهای استخراج شده از ریزحالت‌ها نیز استفاده کرده‌ام:

- نرخ رخداد (Occurrence)
- طول زمانی (Duration)
- پوشش (Coverage)

۴.۴ معیار ارزیابی

از آنجایی که در بررسی ریزحالت‌ها اکثر اوقات ما حتی برای دو پیاده سازی تقریباً یکسان نتایج متفاوتی می‌گیریم بسیار مهم است در ابتدا برای پیش روی در هر مرحله معیاری را معرفی نماییم. اولین معیار که قابل استناد می‌باشد بررسی توپوگرافی خوشها ریزحالت‌ها است چرا که مشاهده شده در اکثر اوقات برای افراد سالم و بیمار (بسته به نوع بیماری) توپوگرافی خوشها شمایل تقریباً یکسانی دارند (جدا از برچسب‌های A,B,C,D که استانداردی برای جایگشت‌های آن وجود ندارد). از همین رو در بررسی نتایج و توضیحات، پیاده سازی انجام گرفته تطابق مناسبی با معیار global موجود دارد.

از دیگر معیارهای ارزیابی مناسب بررسی آماری خوشها می‌باشد. ما بعضاً می‌توانیم تفاوت چشمگیری میان خوشها ای افراد سالم و بیمار در مقایسه با یکدیگر و خودشان بینیم. برای بررسی این تفاوت از معیارهای

آماری مانند p-value و ... استفاده می شود که پیشتر راجع به آن بحث شد. همچنین برای ارزیابی این تفاوت می توان به مقایسه پارامتری منتج شده از ریزحالتها پرداخت که در این پیاده سازی از این معیار برای مقایسه استفاده شده است.

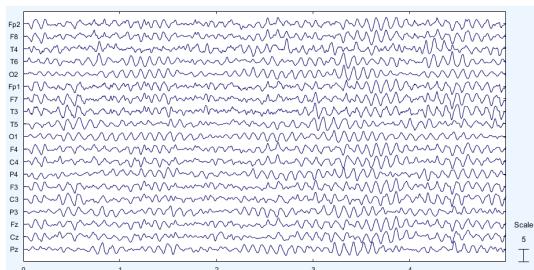
معیار بسیار مهم و نهایی دیگر بررسی صحت و دقت (precision and accuracy) طبقه بندی انجام شده است که پیاده سازی ما را در نهایت ارزیابی می کند.

۵.۴ نتایج و توضیحات

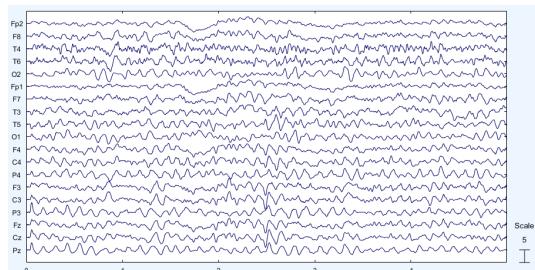
۱.۵.۴ نمایش داده چند نمونه پس از پیش پردازش

پس از انجام پیش پردازش، داده چند فرد مورد آزمایش به شکل زیر بود (برای نمایش بهتر normalization انجام شده است) :

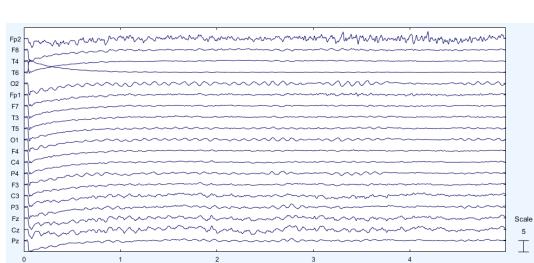
افراد بیمار



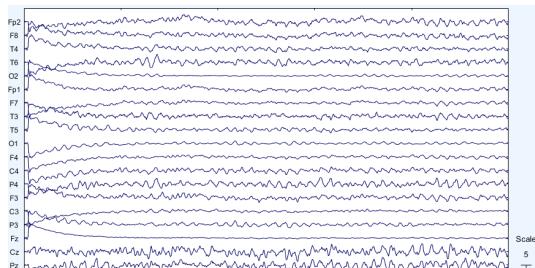
شکل ۲.۴: ۸۴۰ ثانیه از داده بیمار شماره ۳



شکل ۱.۴: ۸۴۰ ثانیه از داده بیمار شماره ۱

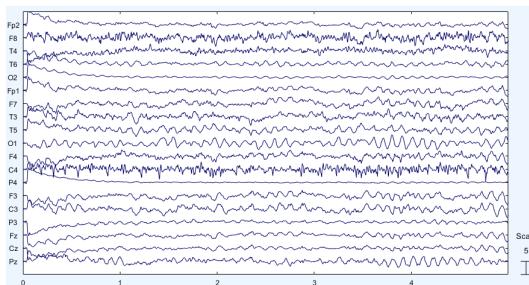


شکل ۴.۴: ۸۴۰ ثانیه از داده بیمار شماره ۱۱

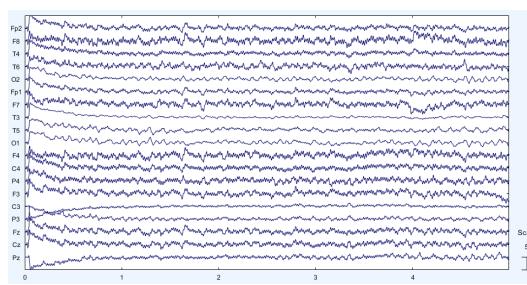


شکل ۳.۴: ۸۴۰ ثانیه از داده بیمار شماره ۹

فصل ۴. پیاده سازی

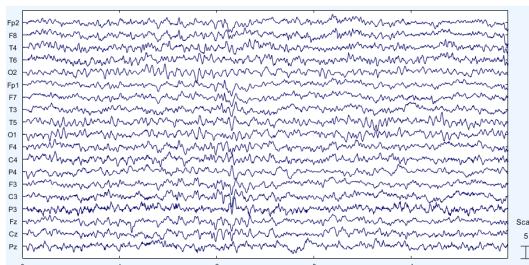


شکل ۶.۴: ۸۴۰ ثانیه از داده بیمار شماره ۱۴

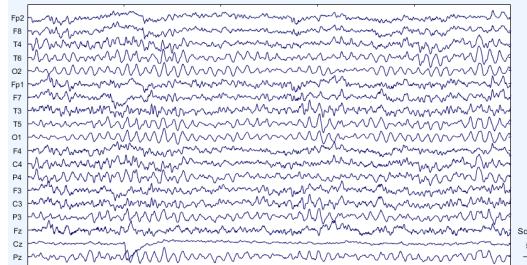


شکل ۵.۴: ۸۴۰ ثانیه از داده بیمار شماره ۱۲

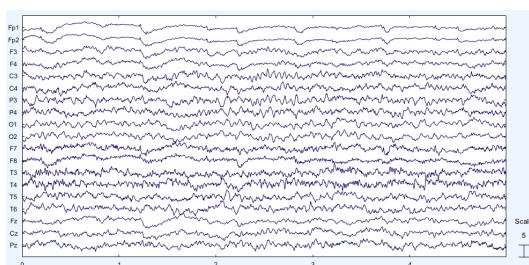
افراد سالم



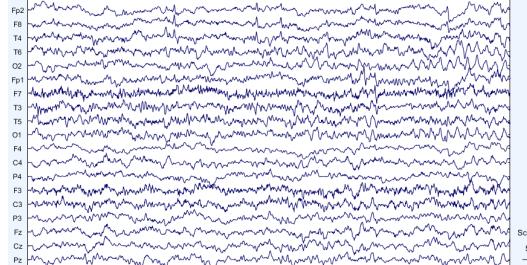
شکل ۸.۴: ۸۴۰ ثانیه از داده فرد سالم شماره ۴



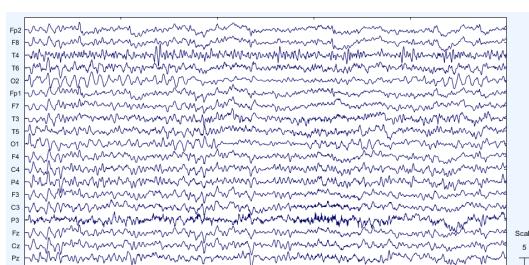
شکل ۷.۴: ۸۴۰ ثانیه از داده بیمار شماره ۱



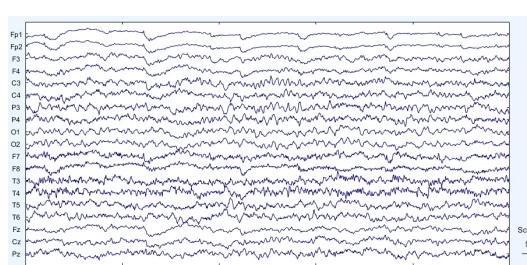
شکل ۱۰.۴: ۸۴۰ ثانیه از داده بیمار شماره ۱۰



شکل ۹.۴: ۸۴۰ ثانیه از داده بیمار شماره ۸



شکل ۱۲.۴: ۸۴۰ ثانیه از داده بیمار شماره ۱۲

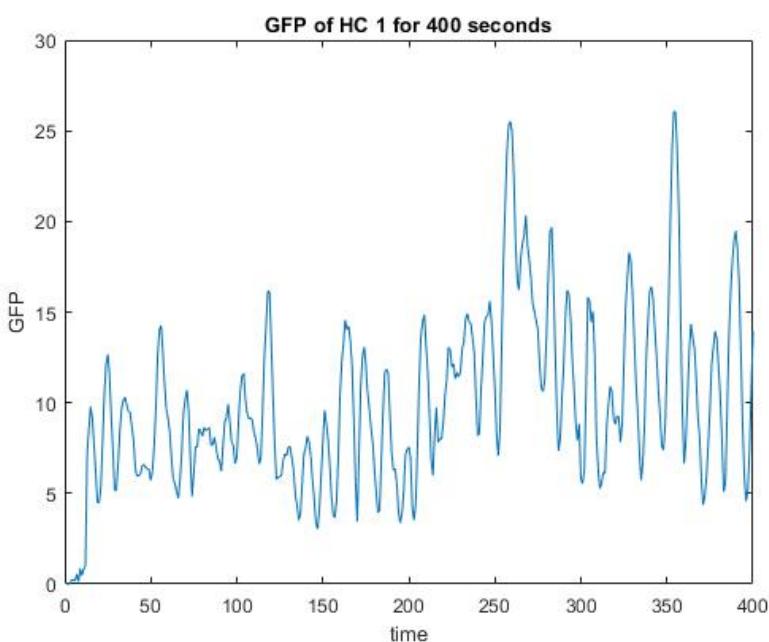


شکل ۱۱.۴: ۸۴۰ ثانیه از داده بیمار شماره ۱۱

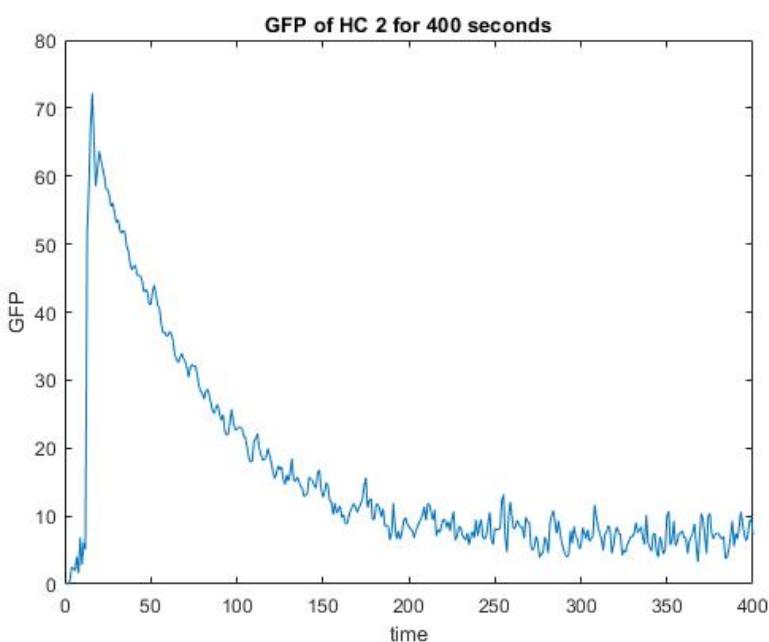
۲.۵.۴ نمایش GFP چند نمونه

- افراد سالم :

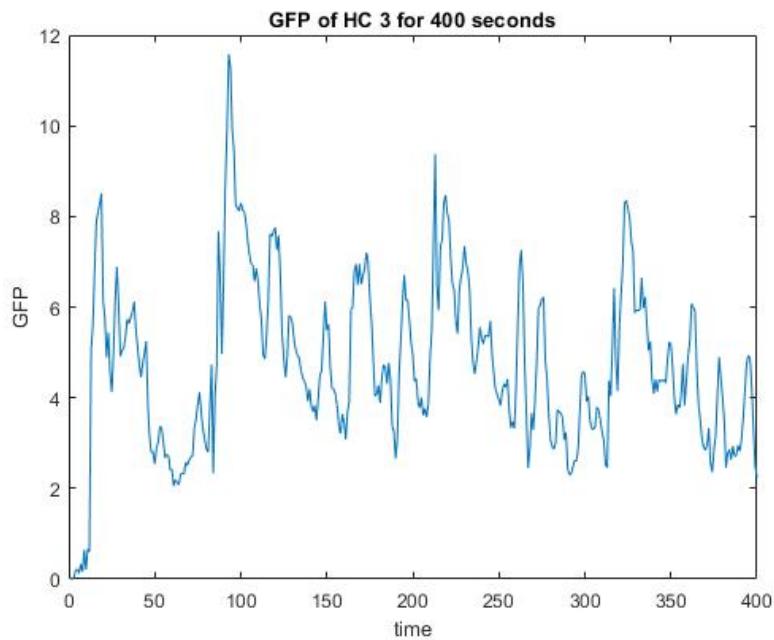
در اینجا برای مشاهده مکرریم‌های محلی (برای بدست آوردن خوش‌ها حائز اهمیت هستند) بجای ۸۴۰ ثانیه داده از ۴۰۰ ثانیه ابتدایی برای نمایش استفاده شده است.



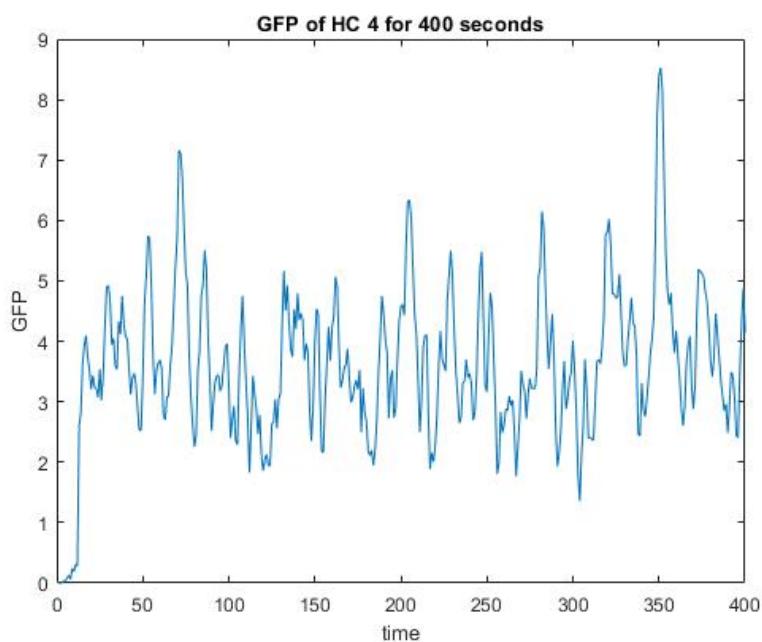
شکل ۱۳-۴ GFP برای ۴۰۰ ثانیه از داده فرد سالم شماره ۱



شکل ۱۴-۴ GFP برای ۴۰۰ ثانیه از داده فرد سالم شماره ۲



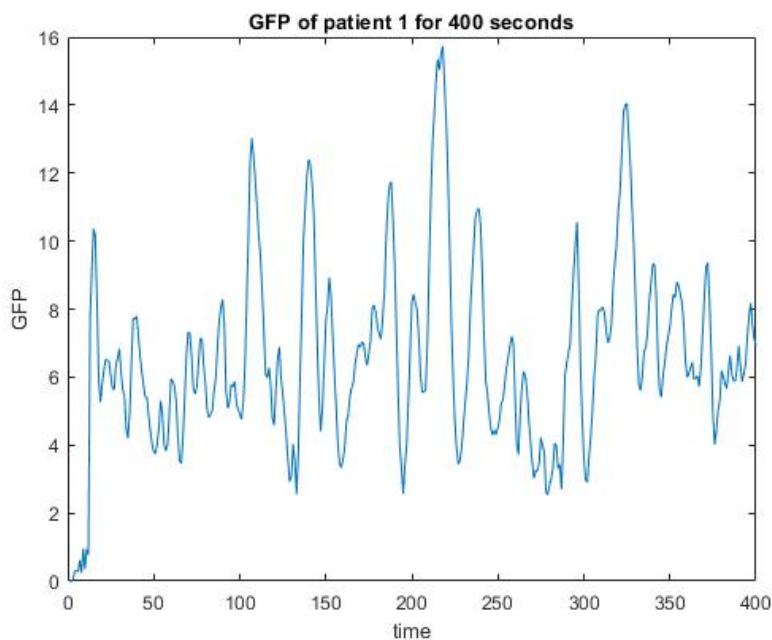
شکل ۱۵-۴ GFP برای ۴۰۰ ثانیه از داده فرد سالم شماره ۳



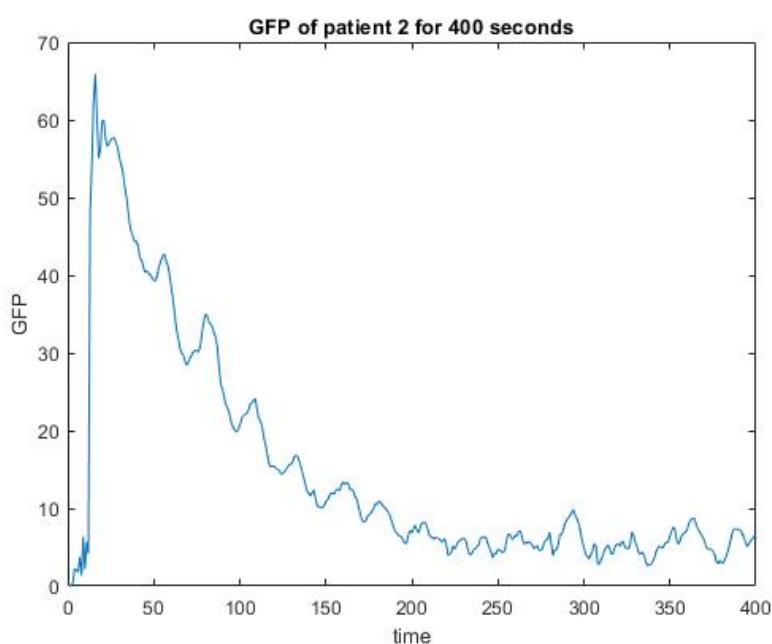
شکل ۱۶-۴ GFP برای ۴۰۰ ثانیه از داده فرد سالم شماره ۴

- افراد بیمار :

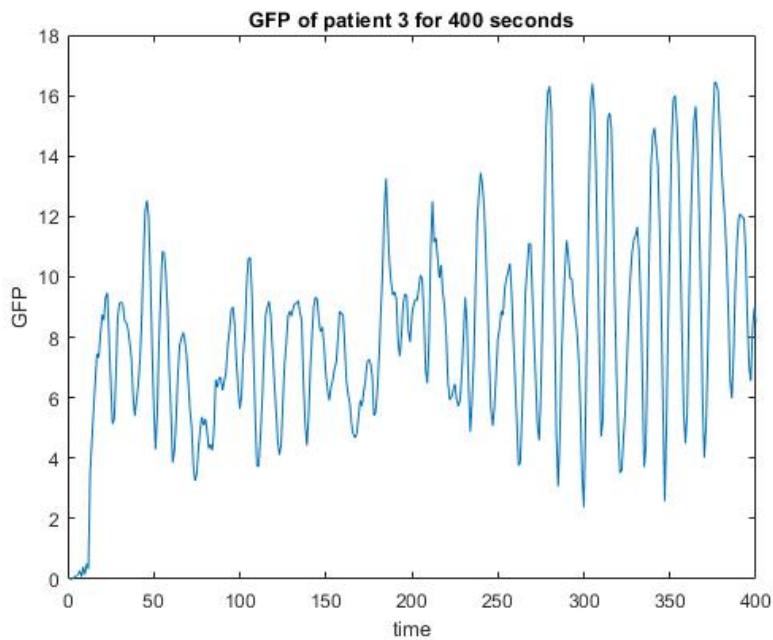
در اینجا برای مشاهده مراکزیم های محلی (برای بدست آوردن خوشها حائز اهمیت هستند) بجای ۸۴۰ ثانیه ابتدایی برای نمایش استفاده شده است.



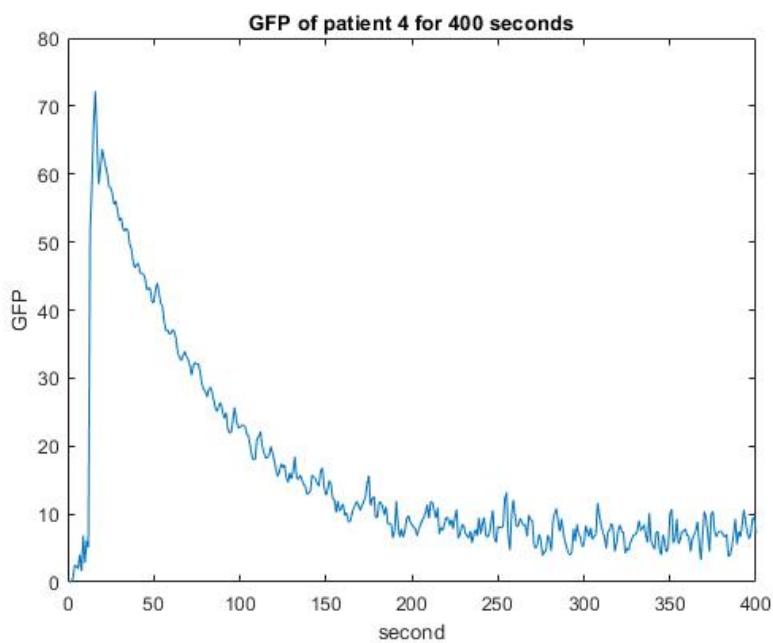
شکل ۱۷-۴ GFP برای ۴۰۰ ثانیه از داده فرد بیمار شماره ۱



شکل ۱۸-۴ GFP برای ۴۰۰ ثانیه از داده فرد بیمار شماره ۲



شکل ۱۹-۴ GFP برای ۴۰۰ ثانیه از داده فرد بیمار شماره ۳



شکل ۲۰-۴ GFP برای ۴۰۰ ثانیه از داده فرد بیمار شماره ۴

همانطور که در بخش ۱.۵.۴ مشاهده می‌شد داده چند نمونه (subject) روند متفاوتی با دیگر نمونه‌ها دارد که در GFP محاسبه شده نیز مشهود می‌باشد. با مطالعه مقاله‌های مربوطه نیز علت این موضوع را متوجه نشدم زیرا صحبتی درباره این مسئله نشده بود.

۳.۵.۴ تعداد خوش بھینه برای نمونه ها در هر کلاس

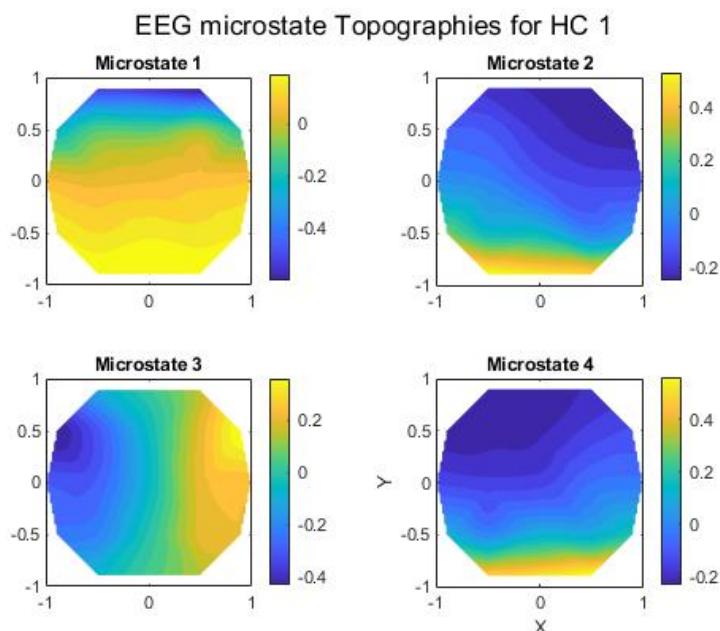
جدول ۲-۴ خوش بندی داده

| سالم | بیمار | |
|----------|----------|-------|
| ۱۲ نمونه | ۱۱ نمونه | ۴ خوش |
| ۲ نمونه | ۳ نمونه | ۵ خوش |

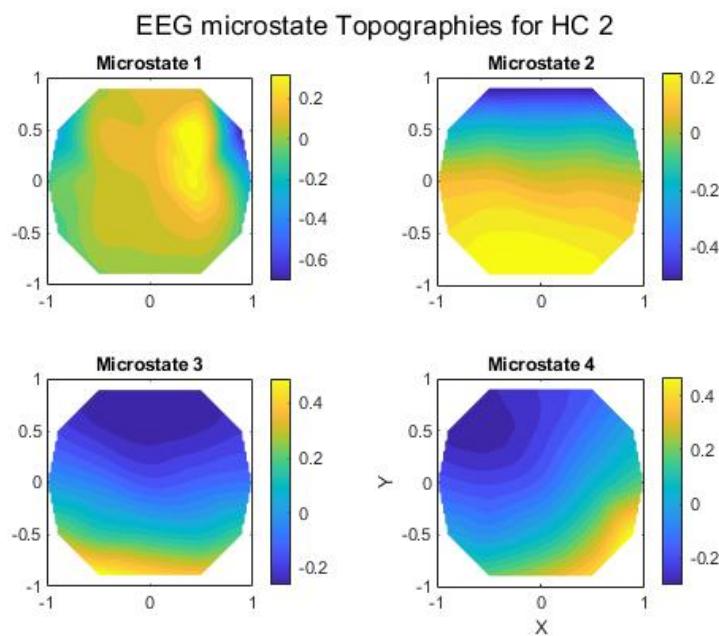
همانطور که مشاهده می شود (طبق جدول ۲-۴ و توضیحات پیش رو) در تمامی نمونه ها برای هر کلاس به تعداد خوش بھینه یکسانی نرسیدیم اما برای اکثر نمونه ها به ۴ خوش رسانیده ایم، برای هر کلاس بیمار و سالم ۴ خوش را به عنوان تعداد خوش بھینه یا اپتیمم در نظر می گیریم.

۴.۵.۴ نمایش توپوگرافی

- در ابتدا برای چند نمونه توپوگرافی ها را نشان می دهیم.
- افراد سالم:

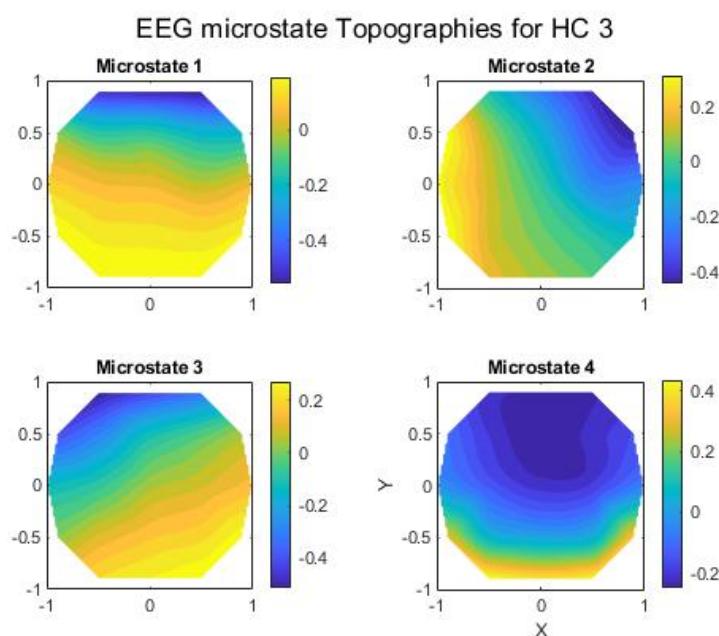


شکل ۴-۲۱ توپوگرافی برای فرد سالم شماره ۱

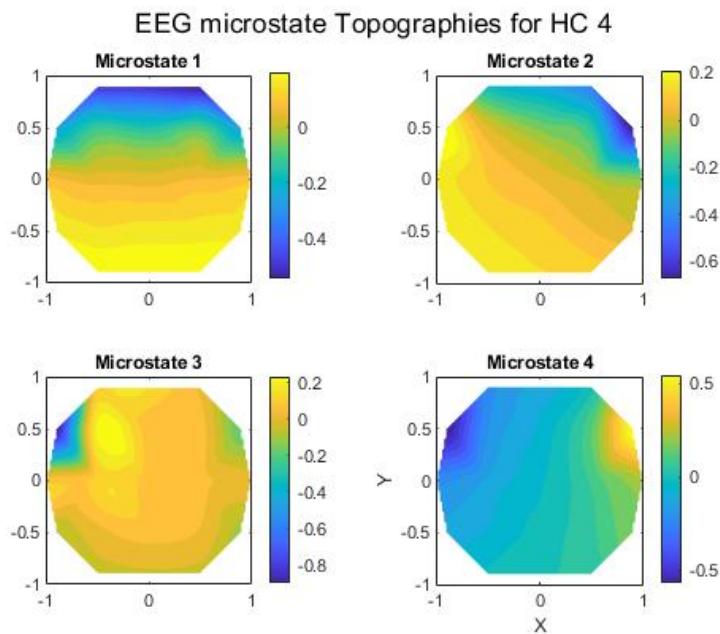


شکل ۴-۲۲ توپوگرافی برای فرد سالم شماره ۲

ریزحالت B خروجی جالبی ندارد!

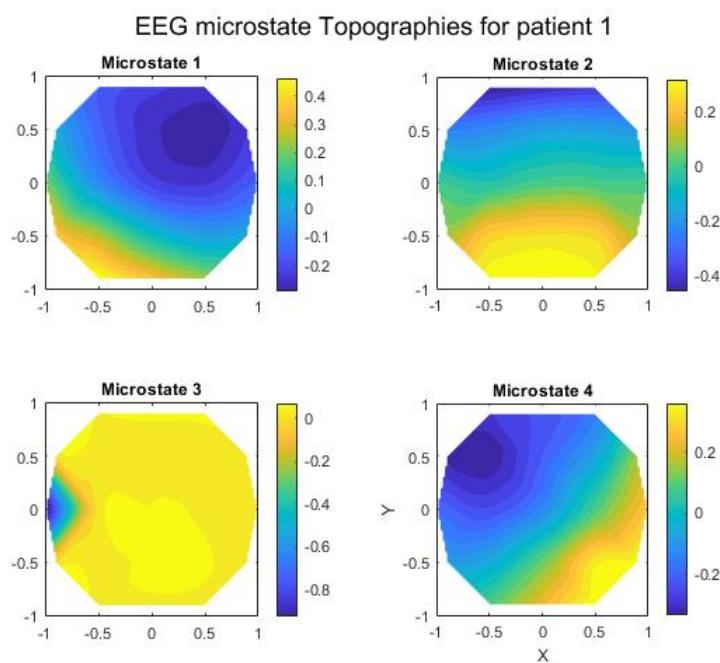


شکل ۴-۲۳ توپوگرافی برای فرد سالم شماره ۳

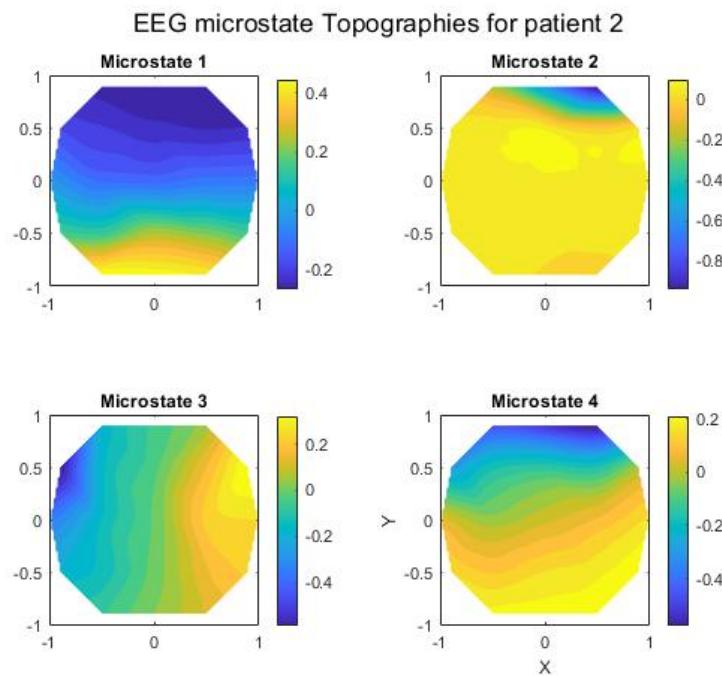


شکل ۴-۲۴ توپوگرافی برای فرد سالم شماره ۴

- افراد بیمار:

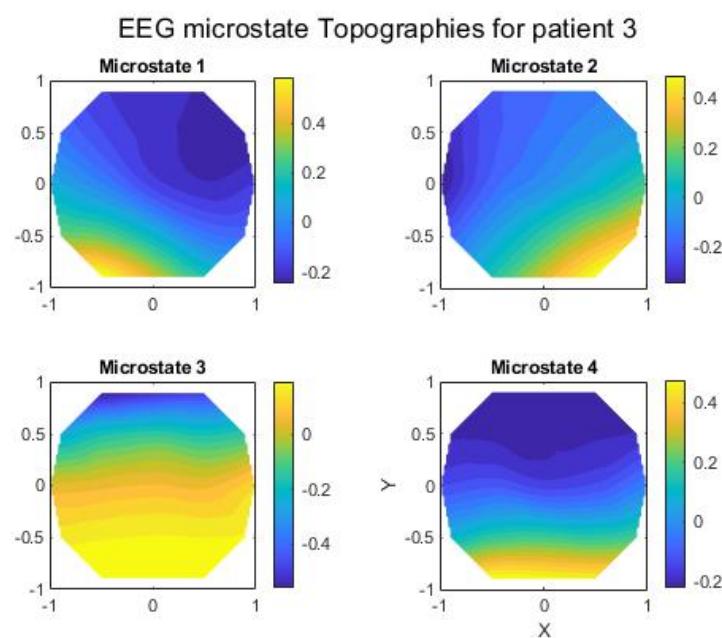


شکل ۴-۲۵ توپوگرافی برای فرد بیمار شماره ۱

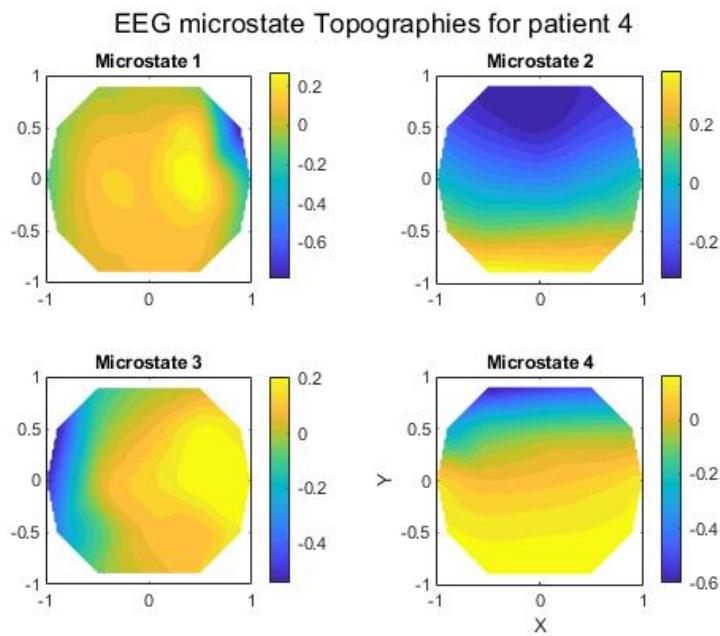


شکل ۴-۲۶ توپوگرافی برای فرد بیمار شماره ۲

ریزحالت B و C خروجی جالبی ندارند!

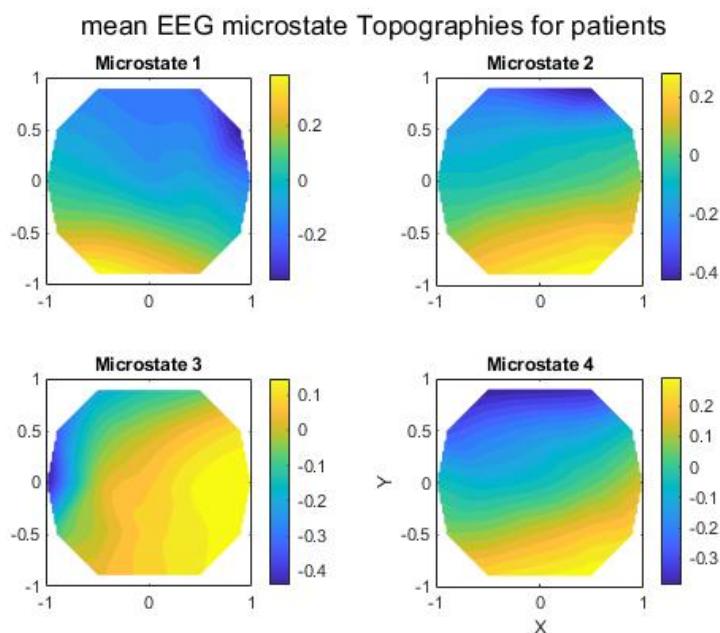


شکل ۴-۲۷ توپوگرافی برای فرد بیمار شماره ۳

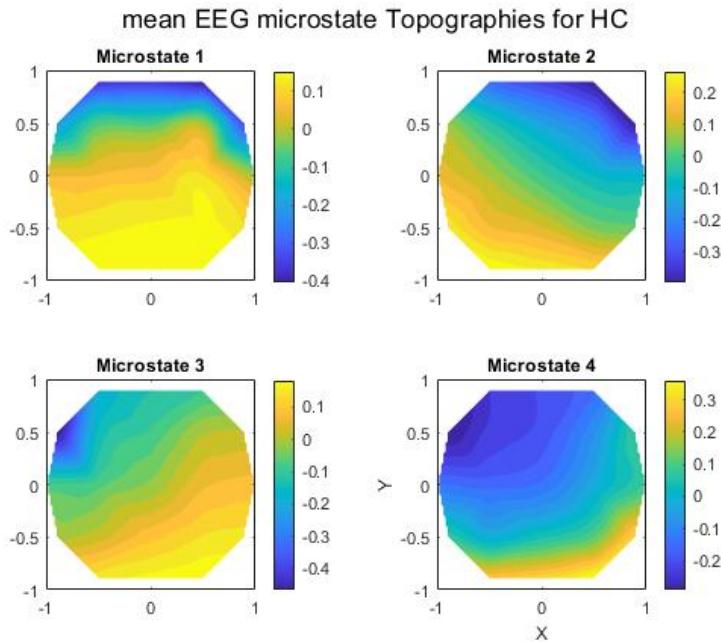


شکل ۴-۲۸ توپوگرافی برای بیمار سالم شماره ۴

در بخش معیار ارزیابی گفتیم کی از معیارها بررسی توپوگرافی خوشه‌های اپتیمیم هر کلاس با استاندارد global است. آنچه در شکل ۴-۲۵ برای گروه بیماران مشاهده می‌شود شباهت بسیار بالا در ریزحالت‌های A,C,D می‌باشد و تنها ریزحالت B تفاوت بیشتری داشت. برای گروه افراد سالم در شکل ۴-۲۶ زیادی در ریزحالت‌های C با استاندارد global دیده می‌شود و در ریزحالت D با استاندارد global تفاوت داشت. توپوگرافی برای کل افراد بیمار و سالم با میانگین گیری روی تمام توپوگرافی‌های نمونه‌ها انجام شده است (طبق [۱]).



شکل ۴-۲۹ توپوگرافی نمونه‌های بیمار



شکل ۴-۳۰ توپوگرافی نمونه‌های سالم

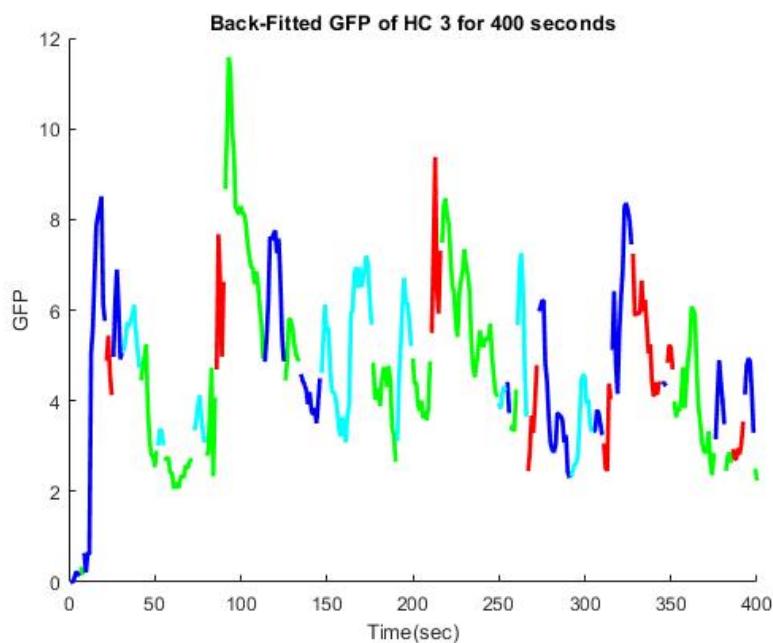
- نکته : تمام توپوگرافی‌ها به صورت دستی با استفاده از تابع `plottopo` که به صورت دستی آن را زده‌ام ترسیم شده‌اند. به وضوح توپوگرافی نشان دهنده نقشه مغزی حاصل از اندازه گیری‌های الکتروودها هستند.

۵.۵.۴ تطبیق خوشها بر روی GFP

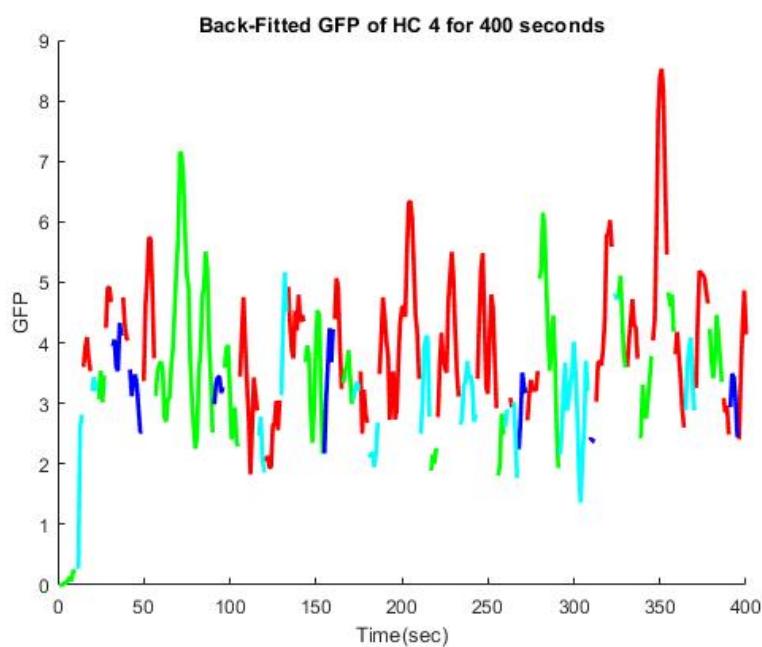
در این بخش تابع `plotmicrostateSequences` به صورت دستی برای تطبیق ۴ ریزحالت اپتیمم روی سیگنال GFP استفاده شده است و نتایج آن به شرح زیر می‌باشد :

- رنگ قرمز : microstate A
- رنگ سبز : microstate B
- رنگ فیروزه‌ای : microstate C
- رنگ آبی : microstate D

-افراد سالم:

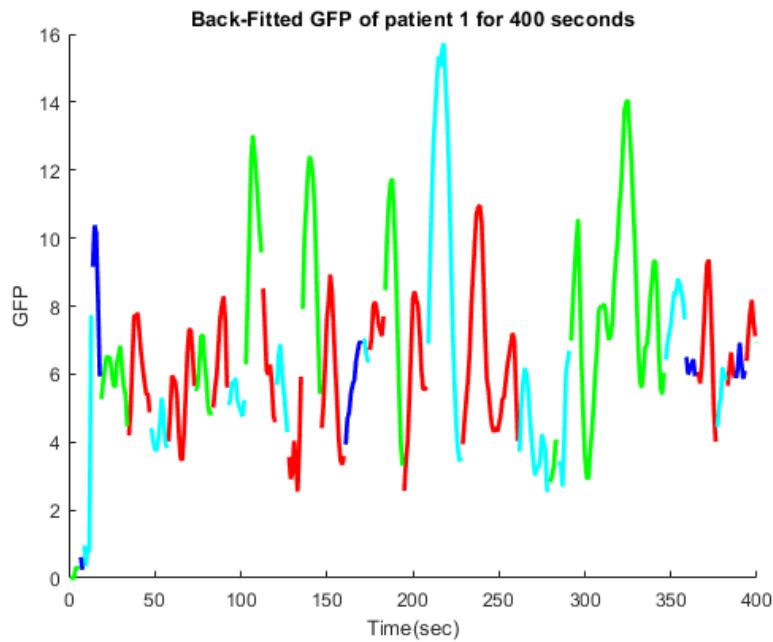


شکل ۴-۳۱ تطبیق خوشهای اپتیمیم بر روی GFP برای فرد سالم ۱

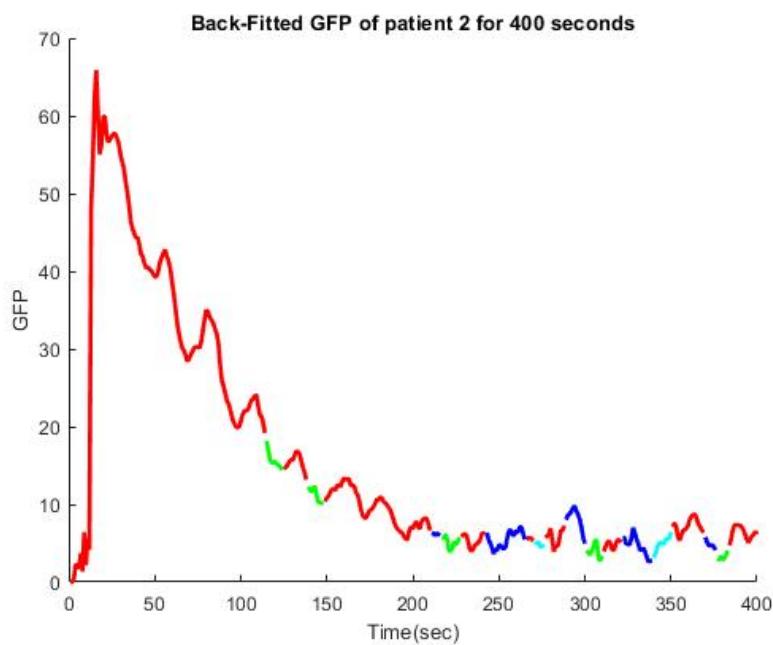


شکل ۴-۳۲ تطبیق خوشهای اپتیمیم بر روی GFP برای فرد سالم ۲

– افراد بیمار:



شکل ۴-۳۳ تطبیق خوشهای اپتیم بر روی GFP برای فرد بیمار ۱



شکل ۴-۳۴ تطبیق خوشهای اپتیم بر روی GFP برای فرد بیمار ۲

۶.۵.۴ پارامترهای خروجی

جدول ۴-۳ پارامترهای خروجی نمونه‌ها

| پارامترها | افراد بیمار | | | | افراد سالم | | | |
|-------------------|-------------|------|------|------|------------|------|------|------|
| | A | B | C | D | A | B | C | D |
| میانگین نرخ رخداد | 0.81 | 0.84 | 0.45 | 0.91 | 0.77 | 0.78 | 0.55 | 0.63 |
| میانگین طول زمانی | 25.6 | 29.4 | 18.2 | 36.9 | 30.1 | 32.6 | 12.4 | 21.6 |
| میانگین پوشش | 19.5 | 19.1 | 17.4 | 31.5 | 21.7 | 22.0 | 14.6 | 18.8 |

در این پیاده سازی میانگین نرخ رخداد عددی بین ۰ و ۱ است و ما مقادیر epoch‌ها را جمع نکرده و میانگین را محاسبه کردہ‌ایم.

طبق جدول ۳-۴ در افراد بیمار و سالم ریزحالت‌های A, B, C, D تفاوت مشهودی در میانگین طول زمانی دارند و همچنین بین دو گروه ریزحالت D نیز تفاوت معنا داری وجود دارد. البته پیاده سازی تحلیل آماری می‌تواند مقایسه واضح‌تر و قابل اطمینان‌تری را به ما ارائه کند.

ما این پارامترها را بر اساس فرمول‌هایی که در بخش ۵.۲ بیان شد محاسبه کردیم و در پیاده سازی نیز توابع calculateOccurrence و calculateDurations استفاده کردہ‌ایم.

۷.۵.۴ طبقه بندی

در مقاله‌ای که از این پایگاه داده استفاده شده بود در مجموع از میان طبقه بندی‌های متعدد استفاده شده، طبقه بند SVM بیشترین دقت را به ما می‌داد. من از دو طبقه بند SVM و MLP استفاده کرده‌ام که در نهایت SVM طبقه بندی بهتری را برای ما انجام داد. در بحث طبقه بندی یکبار با استفاده از ویژگی‌های Conventional و یکبار با استفاده از پارامترهای ریزحالت‌ها طبقه بندی انجام شده است که در نهایت دقت طبقه بندی با ریزحالت‌ها بالاتر بوده است.

جدول ۴-۴ طبقه بندی پایگاه داده میان دو کلاس بیمار و سالم

| ویژگی | دقت پیاده سازی | | دقت مقاله |
|--------------|----------------|------|-----------|
| | SVM | MLP | |
| Conventional | 65.7 | 66.4 | 67.62 |
| ریزحالت‌ها | 63.3 | 68.2 | 75.64 |

شرح نحوه طبقه بندی:

نحوه طبقه بندی ما برای ویژگی‌های conventional و ریزحالت‌ها دو رویکرد با تفاوت در جزئیات بوده است. برای ویژگی‌های conventional ما ماتریس ویژگی (feature matrix) را بر اساس epoch‌های ۵ ثانیه‌ای تشکیل داده‌ایم اما برای ویژگی‌های ریزحالت‌ها ماتریس ویژگی را بر اساس کل دیتای هر نمونه subject ساخته‌ایم و سپس طبقه بندی کردیم.

البته باید اشاره کنیم در مقاله‌های گوناگون دو روش مختلف را برای تشکیل feature matrix به کار برده بودند؛ یک روش که پیش‌تر شرح داده شد و روش دیگر تشکیل ماتریس ویژگی با در نظر گرفتن epoch‌ها بود.

۶.۴ نتیجه گیری

همانطور که در بخش های ۶.۵.۴ و ۷.۵.۴ مشاهده کردیم ویژگی های ریز حالت ها به ما امکان طبقه بندی نسبتاً مناسبی را می دهد. در مسیر پیاده سازی با چالش های متعددی مواجه شدیم که در نهایت با نظر گرفتن ملزومات بیان شده در فصل ۴ به خروجی مناسبی دست پیدا کردیم. معیارهای ازیابی ما در خروجی نیز مقایسه پارامترهای بین شده در جدول ۳-۴، طبقه بندی انجام شده در جدول ۴-۴ و شباهت توپوگرافی های کلاس بیماران و افراد سالم می باشد. با در نظر گرفتن مقاله مربوطه و نتایج بدست آمده ما شاهد کارکرد مناسب ریز حالت ها برای بررسی رفتار سیگنال های مغزی EEG بودیم.

فصل ۵

نتیجه گیری و پیشنهادات

۱.۵ جمع بندی و نتیجه گیری

در یک جمله می‌توان گفت ریزحالت‌ها ویژگی مناسبی از سیگنال مغزی EEG در طبقه بندی سیگنال‌های مغزی بیماران صرعنی هستند؛ چرا که در مقالات مطالعه شده مشاهده کردیم با استفاده از پارامترهای ریزحالت‌ها طبقه بندی با دقت بالایی (اکثراً بالای ۷۵ درصد) انجام شده است و همچنین مشاهده کردیم این پارامترها در مقایسه میان گروه بیماران صرعنی و نمونه‌های دیگر تفاوت قابل توجهی دارند.

آنچه ما در پیاده سازی خود مشاهده کردیم طبقه بندی مناسب بیماران و افراد سالم با استفاده از ریزحالت‌ها و پارامترهای مربوط به آن بود. همچنین با مقایسه پارامترهای بدبست آمده میان دو کلاس و همچنین میان ریزحالت‌های مختلف یک کلاس می‌توان تفاوت‌های معناداری را مشاهده کرد که به بررسی تفاوت رفتاری سیگنال‌های مغزی EEG کمک می‌کند، البته برای نتیجه گیری دقیق‌تر بایستی تحلیل‌های آماری انجام شود. بنابراین ریزحالت‌ها برای طبقه بندی سیگنال‌های مغزی افراد سالم و بیمار مناسب هستند؛ این موضوع نوید ادامه پژوهش‌ها در این زمینه را می‌دهد.

۲.۵ پیشنهادات

بازتابنده به نتایج گرفته شده می‌توان از مسئله طبقه‌بندی فراتر رفت و حتی از ریزحالت‌ها و پارامترهای آن برای پیش‌بینی وقوع بیماری‌ها یا علائم آن‌ها استفاده کنیم. همچنین مشاهده تاثیر داروهای مختلف بر پارامترهای ریزحالت‌ها نیز می‌تواند مبحث جذابی برای بررسی باشد. گمان می‌رود با پیاده سازی شبکه‌های عمیق بر روی پایگاه‌های داده موجود بر اساس ریزحالت‌ها بتوان خروجی‌های به مراتب بهتری را بدست آورد. پیاده سازی تحلیل‌های آماری مناسب برای مقایسه دو کلاس بسیار کارآمد بوده و می‌تواند شهود خوبی از کارکرد ریزحالت‌ها در مقایسه نام برده بدهند.

فصل ٦

مراجع

- [1] Hong Liu, Haoling Tang, Wei Wei, Gesheng Wang, Yong Du, Jianghai Ruan, "Altered peri-seizure EEG microstate dynamics in patients with absence epilepsy," European Journal of Epilepsy, 1.vol. 1, no. 1, pp. 7, 2021
- [2] Han Li, Qizhong Zhang, "intrinsic brain activity in temporal lobe epilepsy with and without depression: insights from EEG microstates," European Journal of Epilepsy, 1.vol. 1, no. 1, pp. 9, 2023
- [3] Ding Liu, Wen Zheng and Zhi Song, "EEG Microstate Features as an Automatic Recognition Model of High-Density Epileptic EEG Using Support Vector Machine," 1.vol. 1, no. 1, pp. 16, 2022
- [4] Yueqian Sun1, Guoping Ren, "Altered Resting-State Electroencephalography Microstates in Idiopathic Generalized Epilepsy: A Prospective Case-Control Study," European Journal of Epilepsy, 1.vol. 1, no. 1, pp. 7, 2021
- [5] Jiechuan Ren, "Where Does EEG Come From and What Does It Mean?," 1.vol. 1, no. 1, pp. 8, 2019
- [6] Qun Wang, Simon Fong, "Epileptic Seizures Prediction Using Machine Learning Methods," Marko Gosak, 1.vol. 1, no. 1, pp. 14, 2017
- [7] Ali Muhamed Ali, Nurgun Erdol, "EEG-based classification of epilepsy and PNES: EEG microstate and functional brain network features," 1.vol. 1, no. 1, pp. 22, 2020
- [8] "Spike-microstates correlate with interictal epileptogenic discharges: a marker for hidden epileptic activity," European Journal of Epilepsy, 1.vol. 1, no. 1, pp. 7, 2023
- [9] Kais Gadhoumi, Jean Gotman, "EEG Microstates analysis in patients with epilepsy," 1.vol. 1, no. 1, pp. 7, 2021
- [10] Hanqi Zhuang1, Emmanuelle Tognoli, "intrinsic brain activity in temporal lobe epilepsy with and without depression: insights from EEG microstates," European Journal of Epilepsy, 1.vol. 1, no. 1, pp. 11, 2016
- [11] Deng-Shan Shiau, Wanpracha Chaovalltwongse, "Altered peri-seizure EEG microstate

- dynamics in patients with absence epilepsy,"European Journal of Epilepsy,1.vol. 1, no. 1, pp. 7, 2021
- [12] Shaik Jakeer Hussain, Gurajapu Raja Sumant, "Epileptic Seizures Prediction Using Machine Learning Method,"European Journal of Epilepsy, 1.vol. 1, no. 1, pp. 15, 2022
- [13] "<https://www.webmd.com/epilepsy/types-epilepsy/>"
- [14] "<https://www.analyticsvidhya.com/>"
- [15] "<https://scikit-learn.org/>"
- [16] "<https://www.geeksforgeeks.org/>"
- [17] Wen Zheng and Zhi Song, "An automated detection of epileptic seizuresEEG using CNN classifier based on feature fusionwith high accuracy,"European Journal of Epilepsy,1.vol. 1, no. 1, pp. 10, 2020
- [18] Hongwei Jiang1, Ganqin Du, "Electrocorticographic Activation Patterns of ElectroencephalographicMicrostates,"1.vol. 1, no. 1, pp. 9, 2018
- [19] Ritam Bandopadhyay, Tanveer Singh, Mohammed M. Ghoneim, Sultan Alshehri, Efthalia Angelopoulou, "Recent Developments in Diagnosis of Epilepsy: Scopeof MicroRNA and Technological Advancements,"1.vol. 1, no. 1, pp. 38, 2019
- [20] Kyungwon Kim, Nguyen Thanh Duc,Min Choi, Boreom Lee, "EEG microstate features for schizophrenia classification,"1.vol. 2, no. 3, pp. 21, 2021